


Regressione lineare


Alessandro Toigo

- **Statistica descrittiva**
(riassumere molti dati attraverso poche caratteristiche essenziali)
- **Probabilità**
(costruire un modello che preveda il risultato di un esperimento)
- **Inferenza statistica**
(tarare i parametri del modello in base ai risultati dell'esperimento)
- **Regressione lineare**
(riconoscere relazioni tra dati di tipo diverso)


Modelli empirici



Idealmente:




Gas perfetto




Corrente-tensione


Modelli empirici



Idealmente:




Gas perfetto




Corrente-tensione


Modelli empirici



Realisticamente:




Gas perfetto




Corrente-tensione


Modelli empirici



Vogliamo trovare f !




Gas perfetto



Corrente-tensione

Modello lineare

Per n punti passa sempre un polinomio di grado $n - 1$:




Modello lineare

Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .



Modello lineare


Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .

Come si capisce se la retta di parametri (a, b) approssima bene gli n punti?



Modello lineare


Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .

Come si capisce se la retta di parametri (a, b) approssima bene gli n punti?



Dobbiamo introdurre gli errori (o *residui*)

$$e_i := y_i - (a + bx_i)$$

e un funzionale di errore

$$L(a, b) := \sum_{i=1}^n (y_i - a - bx_i)^2 = \sum_{i=1}^n e_i^2$$

Modello lineare


Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .

Come si capisce se la retta di parametri (a, b) approssima bene gli n punti?



Dobbiamo introdurre gli errori (o *residui*)

$$e_i := y_i - (a + bx_i)$$

e un funzionale di errore

$$L(a, b) := \sum_{i=1}^n (y_i - a - bx_i)^2 = \sum_{i=1}^n e_i^2$$

Modello lineare


Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .

Come si capisce se la retta di parametri (a, b) approssima bene gli n punti?



Dobbiamo introdurre gli errori (o *residui*)

$$e_i := y_i - (a + bx_i)$$

e un funzionale di errore

$$L(a, b) := \sum_{i=1}^n (y_i - a - bx_i)^2 = \sum_{i=1}^n e_i^2$$

Modello lineare


Per n punti passa sempre un polinomio di grado $n - 1$:

Ma noi vogliamo la funzione più semplice possibile: la retta

$$y = a + bx$$

parametrizzata solo da (a, b) .

Come si capisce se la retta di parametri (a, b) approssima bene gli n punti?



Dobbiamo introdurre gli errori (o *residui*)

$$e_i := y_i - (a + bx_i)$$


e un funzionale di errore

$$L(a, b) := \sum_{i=1}^n (y_i - a - bx_i) \quad \textcircled{2} = \sum_{i=1}^n e_i \quad \textcircled{2}$$

Perché si mette
il quadrato?


Modello lineare

Col quadrato:



- $L(a, b) \geq 0 \forall (a, b)$
- $L(\infty) = +\infty$
- $\exists!$ punto di minimo (\hat{a}, \hat{b})


Senza quadrato:



- i residui si compensano
- \nexists minimo

Modello lineare


Col quadrato:



- $L(a, b) \geq 0 \forall (a, b)$
- $L(\infty) = +\infty$
- $\exists!$ punto di minimo (\hat{a}, \hat{b})

$y = \hat{a} + \hat{b}x$ è la *retta dei minimi quadrati* (LSL = *least square line*)

Senza quadrato:



- i residui si compensano
- \nexists minimo

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\frac{\partial L}{\partial a} = \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - a - bx_i)^2$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial a} &= \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n (y_i - a - bx_i)\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial a} &= \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n (y_i - a - bx_i) \\ &= -2(n\bar{y} - na - nb\bar{x})\end{aligned}$$

dove

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i.$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial a} &= \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n (y_i - a - bx_i) \\ &= -2(n\bar{y} - na - nb\bar{x}) \\ &\equiv 0\end{aligned}$$

dove

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i.$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial a} &= \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n (y_i - a - bx_i) \\ &= -2(n\bar{y} - na - nb\bar{x}) \\ &\equiv 0 \\ &\Rightarrow \quad a = \bar{y} - b\bar{x}\end{aligned}$$

dove

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i.$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\frac{\partial L}{\partial b} = \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n x_i (y_i - a - bx_i)\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\ &= -2 \sum_{i=1}^n x_i (y_i - a - bx_i) \\ &= -2 \left(\sum_{i=1}^n x_i y_i - na\bar{x} - b \sum_{i=1}^n x_i^2 \right)\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\&= -2 \sum_{i=1}^n x_i (y_i - a - bx_i) \\&= -2 \left(\sum_{i=1}^n x_i y_i - na\bar{x} - b \sum_{i=1}^n x_i^2 \right) \\&= -2 \left(\sum_{i=1}^n x_i y_i - n\bar{x}(\bar{y} - b\bar{x}) - b \sum_{i=1}^n x_i^2 \right) \quad \text{con } a = \bar{y} - b\bar{x}\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\&= -2 \sum_{i=1}^n x_i (y_i - a - bx_i) \\&= -2 \left(\sum_{i=1}^n x_i y_i - na\bar{x} - b \sum_{i=1}^n x_i^2 \right) \\&= -2 \left(\sum_{i=1}^n x_i y_i - n\bar{x}(\bar{y} - b\bar{x}) - b \sum_{i=1}^n x_i^2 \right) \quad \text{con } a = \bar{y} - b\bar{x} \\&\equiv 0\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\&= -2 \sum_{i=1}^n x_i (y_i - a - bx_i) \\&= -2 \left(\sum_{i=1}^n x_i y_i - na\bar{x} - b \sum_{i=1}^n x_i^2 \right) \\&= -2 \left(\sum_{i=1}^n x_i y_i - n\bar{x}(\bar{y} - b\bar{x}) - b \sum_{i=1}^n x_i^2 \right) \quad \text{con } a = \bar{y} - b\bar{x} \\&\equiv 0 \\&\Rightarrow \quad b = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}\end{aligned}$$

Retta dei minimi quadrati

Cerchiamo (\hat{a}, \hat{b}) ponendo $\nabla L(\hat{a}, \hat{b}) \equiv 0$:

$$\begin{aligned}\frac{\partial L}{\partial b} &= \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - a - bx_i)^2 \\&= -2 \sum_{i=1}^n x_i (y_i - a - bx_i) \\&= -2 \left(\sum_{i=1}^n x_i y_i - na\bar{x} - b \sum_{i=1}^n x_i^2 \right) \\&= -2 \left(\sum_{i=1}^n x_i y_i - n\bar{x}(\bar{y} - b\bar{x}) - b \sum_{i=1}^n x_i^2 \right) \quad \text{con } a = \bar{y} - b\bar{x} \\&\equiv 0 \\&\Rightarrow \quad b = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_j^2 - n\bar{x}^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_j - \bar{x})^2}\end{aligned}$$

Retta dei minimi quadrati

Dai punti $(x_1, y_1), \dots, (x_n, y_n)$ distilliamo le 5 quantità

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$$

$$s_{xx} := \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_{xy} := \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_{yy} := \sum_{i=1}^n (y_i - \bar{y})^2$$

Retta dei minimi quadrati

Dai punti $(x_1, y_1), \dots, (x_n, y_n)$ distilliamo le 5 quantità

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$$

$$s_{xx} := \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_{xy} := \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_{yy} := \sum_{i=1}^n (y_i - \bar{y})^2$$

Tutte le altre quantità della LSL sono funzioni di queste. P. es.:

$$\hat{a} = \bar{y} - \frac{s_{xy}}{s_{xx}} \bar{x} \quad \hat{b} = \frac{s_{xy}}{s_{xx}} \quad \text{parametri della LSL}$$

Retta dei minimi quadrati

Dai punti $(x_1, y_1), \dots, (x_n, y_n)$ distilliamo le 5 quantità

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$$

$$s_{xx} := \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_{xy} := \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_{yy} := \sum_{i=1}^n (y_i - \bar{y})^2$$

Tutte le altre quantità della LSL sono funzioni di queste. P. es.:

$$\hat{a} = \bar{y} - \frac{s_{xy}}{s_{xx}} \bar{x} \quad \hat{b} = \frac{s_{xy}}{s_{xx}} \quad \text{parametri della LSL}$$

$$\hat{y}_i := \hat{a} + \hat{b}x_i = \bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \quad \text{output della LSL}$$

Retta dei minimi quadrati

Dai punti $(x_1, y_1), \dots, (x_n, y_n)$ distilliamo le 5 quantità

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$$

$$s_{xx} := \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_{xy} := \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_{yy} := \sum_{i=1}^n (y_i - \bar{y})^2$$

Tutte le altre quantità della LSL sono funzioni di queste. P. es.:

$$\hat{a} = \bar{y} - \frac{s_{xy}}{s_{xx}} \bar{x} \quad \hat{b} = \frac{s_{xy}}{s_{xx}} \quad \text{parametri della LSL}$$

$$\hat{y}_i := \hat{a} + \hat{b}x_i = \bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \quad \text{output della LSL}$$

$$\hat{e}_i := y_i - \hat{y}_i = (y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \quad \text{residui della LSL}$$

Varianza totale

$$SS_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

Varianza totale

$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$

Varianza totale


$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare

Varianza totale

$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare
- $ss_t \neq 0$ anche se tutti i punti stanno **esattamente** su una retta:




$$ss_t = 11.98$$

Varianza totale

$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare
- $ss_t \neq 0$ anche se tutti i punti stanno **esattamente** su una retta:



Varianza totale


$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare
- $ss_t \neq 0$ anche se tutti i punti stanno esattamente su una retta
- $ss_t = ss_r + ss_e$, dove:
 - ss_r è intrinseca al modello lineare (varianza *spiegata*)
 - ss_e dipende dalla dispersione intorno alla LSL (varianza *residua*)

Varianza totale

$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare
- $ss_t \neq 0$ anche se tutti i punti stanno esattamente su una retta
- $ss_t = ss_r + ss_e$, dove:
 - ss_r è intrinseca al modello lineare (varianza *spiegata*)
 - ss_e dipende dalla dispersione intorno alla LSL (varianza *residua*)




$$ss_r = 11.98$$

$$ss_e = 0$$

Varianza totale

$$ss_t := s_{yy} = \sum_i (y_i - \bar{y})^2 \quad \text{total sum of squares}$$

- $ss_t \geq 0$
- ss_t non dipende dall'aver scelto il modello lineare
- $ss_t \neq 0$ anche se tutti i punti stanno esattamente su una retta
- $ss_t = ss_r + ss_e$, dove:
 - ss_r è intrinseca al modello lineare (varianza *spiegata*)
 - ss_e dipende dalla dispersione intorno alla LSL (varianza *residua*)



$$ss_r = 11.98$$

$$ss_e = 0.70$$

$$ss_e := \min_{(a,b)} L(a, b)$$

$$ss_e := \min_{(a,b)} L(a, b) = L(\hat{a}, \hat{b})$$

$$ss_e := \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2$$

$$\begin{aligned} ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\ &= \sum_i (y_i - \hat{y}_i)^2 \end{aligned}$$

$$\begin{aligned}ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\&= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2\end{aligned}$$

$$\begin{aligned} ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\ &= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares} \end{aligned}$$

$$\begin{aligned}ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\&= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares}\end{aligned}$$

- $ss_e \geq 0$

$$\begin{aligned}ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\&= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares}\end{aligned}$$

- $ss_e \geq 0$
- $ss_e = 0$ se e solo se tutti i punti stanno **esattamente** su una retta

$$\begin{aligned} ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\ &= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares} \end{aligned}$$

- $ss_e \geq 0$
- $ss_e = 0$ se e solo se tutti i punti stanno **esattamente** su una retta:
 $\Rightarrow: \quad ss_e = 0 \quad \Rightarrow \quad (y_i - \hat{a} - \hat{b}x_i)^2 = 0 \text{ per ogni } i$
 $\Rightarrow \quad y_i = \hat{a} + \hat{b}x_i \text{ per ogni } i$

$$\begin{aligned} ss_e &:= \min_{(a,b)} L(a, b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\ &= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares} \end{aligned}$$

- $ss_e \geq 0$
- $ss_e = 0$ se e solo se tutti i punti stanno **esattamente** su una retta:
 $\Rightarrow: ss_e = 0 \Rightarrow (y_i - \hat{a} - \hat{b}x_i)^2 = 0$ per ogni i
 $\Rightarrow y_i = \hat{a} + \hat{b}x_i$ per ogni i
 $\Leftarrow: y_i = a + bx_i$ per ogni $i \Rightarrow L(a, b) = 0$
 $\Rightarrow ss_e = \min_{(a,b)} L(a, b) = 0$

$$\begin{aligned}ss_e &:= \min_{(a,b)} L(a,b) = L(\hat{a}, \hat{b}) = \sum_i (y_i - \hat{a} - \hat{b}x_i)^2 \\&= \sum_i (y_i - \hat{y}_i)^2 = \sum_i \hat{e}_i^2 \quad \text{error sum of squares}\end{aligned}$$

- $ss_e \geq 0$
- $ss_e = 0$ se e solo se tutti i punti stanno esattamente su una retta:
 $\Rightarrow: ss_e = 0 \Rightarrow (y_i - \hat{a} - \hat{b}x_i)^2 = 0$ per ogni i
 $\Rightarrow y_i = \hat{a} + \hat{b}x_i$ per ogni i
 $\Leftarrow: y_i = a + bx_i$ per ogni $i \Rightarrow L(a,b) = 0$
 $\Rightarrow ss_e = \min_{(a,b)} L(a,b) = 0$
- Se $ss_e = 0$, tutti i punti stanno sulla LSL.

$$ss_r := \sum_i (\bar{y} - \hat{y}_i)^2$$

Varianza spiegata

$$SS_r := \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2$$

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2\end{aligned}$$

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}}\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$

Varianza spiegata

$$\begin{aligned} SS_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\ &= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares} \end{aligned}$$

- $SS_r \geq 0$
- $SS_t = SS_r + SS_e$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$ss_e := \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$\begin{aligned}ss_e &:= \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \sum \left[(y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right]^2\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$\begin{aligned}ss_e &:= \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \sum \left[(y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right]^2 = s_{yy} - 2 \frac{s_{xy}}{s_{xx}} s_{xy} + \left(\frac{s_{xy}}{s_{xx}} \right)^2 s_{xx}\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$\begin{aligned}ss_e &:= \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \sum \left[(y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right]^2 = s_{yy} - 2 \frac{s_{xy}}{s_{xx}} s_{xy} + \left(\frac{s_{xy}}{s_{xx}} \right)^2 s_{xx} \\&= s_{yy} - \frac{s_{xy}^2}{s_{xx}}\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$
- $ss_t = ss_r + ss_e$, perché

$$\begin{aligned}ss_e &:= \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \sum \left[(y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right]^2 = s_{yy} - 2 \frac{s_{xy}}{s_{xx}} s_{xy} + \left(\frac{s_{xy}}{s_{xx}} \right)^2 s_{xx} \\&= s_{yy} - \frac{s_{xy}^2}{s_{xx}} = ss_t - ss_r\end{aligned}$$

Varianza spiegata

$$\begin{aligned}ss_r &:= \sum_i (\bar{y} - \hat{y}_i)^2 = \sum_i \left[\bar{y} - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \left(\frac{s_{xy}}{s_{xx}} \right)^2 \sum_i (x_i - \bar{x})^2 = \frac{s_{xy}^2}{s_{xx}} \quad \text{regression sum of squares}\end{aligned}$$

- $ss_r \geq 0$

- $ss_t = ss_r + ss_e$, perché

$$\begin{aligned}\textcolor{red}{ss}_e &:= \sum (y_i - \hat{y}_i)^2 = \sum \left[y_i - \left(\bar{y} + \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right) \right]^2 \\&= \sum \left[(y_i - \bar{y}) - \frac{s_{xy}}{s_{xx}} (x_i - \bar{x}) \right]^2 = s_{yy} - 2 \frac{s_{xy}}{s_{xx}} s_{xy} + \left(\frac{s_{xy}}{s_{xx}} \right)^2 s_{xx} \\&= s_{yy} - \frac{s_{xy}^2}{s_{xx}} = \textcolor{red}{ss}_t - \textcolor{red}{ss}_r\end{aligned}$$

$$r^2 := \frac{SS_r}{SS_t}$$

Coefficiente di determinazione

$$r^2 := \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t}$$

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \end{aligned}$$

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \end{aligned} \quad \text{coefficiente di determinazione}$$

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \quad \text{coefficiente di determinazione} \end{aligned}$$

- $0 \leq r^2 \leq 1$

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \quad \text{coefficiente di determinazione} \end{aligned}$$

- $0 \leq r^2 \leq 1$
- $r^2 \simeq 1 \Rightarrow$ i punti si dispongono bene su una retta

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \quad \text{coefficiente di determinazione} \end{aligned}$$

- $0 \leq r^2 \leq 1$
- $r^2 \simeq 1 \Rightarrow$ i punti si dispongono bene su una retta
- r^2 è la “percentuale di variabilità spiegata dal modello lineare”

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \quad \text{coefficiente di determinazione} \end{aligned}$$

- $0 \leq r^2 \leq 1$
- $r^2 \simeq 1 \Rightarrow$ i punti si dispongono bene su una retta
- r^2 è la “percentuale di variabilità spiegata dal modello lineare”
- $r^2 = \frac{s_{xy}^2 / s_{xx}}{s_{yy}}$

Coefficiente di determinazione

$$\begin{aligned} r^2 &:= \frac{SS_r}{SS_t} = \frac{SS_t - SS_e}{SS_t} \\ &= 1 - \frac{SS_e}{SS_t} \quad \text{coefficiente di determinazione} \end{aligned}$$

- $0 \leq r^2 \leq 1$
- $r^2 \simeq 1 \Rightarrow$ i punti si dispongono bene su una retta
- r^2 è la “percentuale di variabilità spiegata dal modello lineare”
- $r^2 = \frac{s_{xy}^2 / s_{xx}}{s_{yy}} = \frac{s_{xy}^2}{s_{xx} s_{yy}}$

Coefficiente di correlazione

$$r := \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \quad \text{coefficiente di correlazione}$$

Coefficiente di correlazione

$$r := \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \quad \text{coefficiente di correlazione}$$

- $-1 \leq r \leq 1$

Coefficiente di correlazione


$$r := \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \quad \text{coefficiente di correlazione}$$

- $-1 \leq r \leq 1$
- r^2 è il coefficiente di determinazione

Coefficiente di correlazione

$$r := \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \quad \text{coefficiente di correlazione}$$

- $-1 \leq r \leq 1$
- r^2 è il coefficiente di determinazione
- $r > 0.9 \Rightarrow$ i dati approssimano una retta di **pendenza positiva**




$$r = 0.972$$
$$r^2 = 0.945$$

Coefficiente di correlazione

$$r := \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \quad \text{coefficiente di correlazione}$$


- $-1 \leq r \leq 1$
- r^2 è il coefficiente di determinazione
- $r > 0.9 \Rightarrow$ i dati approssimano una retta di pendenza positiva
- $r < -0.9 \Rightarrow$ i dati approssimano una retta di **pendenza negativa**




$$r = -0.972$$

$$r^2 = 0.945$$

Il modello statistico




Il modello statistico



Se facciamo n misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Il modello statistico




Se facciamo n misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Ipotesi fondamentale del modello lineare:

- E_1, E_2, \dots, E_n i. i. d.
- $E_i \sim N(0, \sigma^2)$ con σ^2 incognita

Il modello statistico




Se facciamo n misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Ipotesi fondamentale del modello lineare:

- E_1, E_2, \dots, E_n i. i. d.
 - $E_i \sim N(0, \sigma^2)$ con σ^2 incognita
- $$\Rightarrow \begin{cases} Y_i \sim N(a + bx_i, \sigma^2) \\ Y_1, \dots, Y_n \text{ indipendenti} \end{cases}$$

Il modello statistico



Se facciamo n misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Ipotesi fondamentale del modello lineare:

- E_1, E_2, \dots, E_n i. i. d.
 - $E_i \sim N(0, \sigma^2)$ con σ^2 incognita
- $$\Rightarrow \begin{cases} Y_i \sim N(a + bx_i, \sigma^2) \\ Y_1, \dots, Y_n \text{ indipendenti} \end{cases}$$

Y_1, \dots, Y_n non sono identicamente distribuite

Quali sono le variabili aleatorie nel modello lineare ?

Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No

Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì

Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$s_{xx} = \sum (x_i - \bar{x})^2$	No

Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?


Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$s_{xx} = \sum (x_i - \bar{x})^2$	No
$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	$s_{xY} = \sum (x_i - \bar{x})(Y_i - \bar{Y})$	Sì

Il modello statistico


Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$s_{xx} = \sum (x_i - \bar{x})^2$	No
$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	$s_{xY} = \sum (x_i - \bar{x})(Y_i - \bar{Y})$	Sì
$s_{yy} = \sum (y_i - \bar{y})^2$	$s_{YY} = \sum (Y_i - \bar{Y})^2$	Sì
Ecc.		

Il modello statistico




Il modello statistico



E_i = errori di misura (residui di $y = a + bx$)

NON MISURABILI
perché a, b incogniti


Il modello statistico



E_i = errori di misura (residui di $y = a + bx$)

$\hat{Y} = \hat{A} + \hat{B}x$ interpola i punti $(x_1, Y_1), \dots, (x_n, Y_n)$

Il modello statistico




E_i = errori di misura (residui di $y = a + bx$)

$\hat{Y} = \hat{A} + \hat{B}x$ interpola i punti $(x_1, Y_1), \dots, (x_n, Y_n)$

Riguarderemo (\hat{A}, \hat{B}) come stimatori di (a, b)

Il modello statistico



E_i = errori di misura (residui di $y = a + bx$)

$\hat{Y} = \hat{A} + \hat{B}x$ interpola i punti $(x_1, Y_1), \dots, (x_n, Y_n)$

Riguarderemo (\hat{A}, \hat{B}) come stimatori di (a, b)

\hat{E}_i = residui di $\hat{Y} = \hat{A} + \hat{B}x$

MISURABILI

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_j - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

DIMOSTRAZIONE:

\hat{B} comb. lineare di gaussiane indipendenti $\Rightarrow \hat{B} \sim N$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

DIMOSTRAZIONE:

\hat{B} comb. lineare di gaussiane indipendenti $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

DIMOSTRAZIONE:

\hat{B} comb. lineare di gaussiane indipendenti $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\hat{B}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= b\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(\textcolor{red}{b}, \frac{\sigma^2}{S_{XX}}\right)$$

DIMOSTRAZIONE:

\hat{B} comb. lineare di gaussiane indipendenti $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\textcolor{red}{\hat{B}}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= \textcolor{red}{b}\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

DIMOSTRAZIONE:

\hat{B} comb. lineare di gaussiane indipendenti $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\hat{B}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= b\end{aligned}$$

$$\text{Var}[\hat{B}] = \frac{\sigma^2}{S_{XX}} \quad (\text{più complicato})$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_j - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$\Rightarrow \hat{B}$ stimatore non distorto di b

Se conoscessimo σ^2 , potremmo usare la v. a.

$$\frac{\hat{B} - b}{\sqrt{\sigma^2 / S_{XX}}} \sim N(0, 1)$$

per costruire IC e fare test per il parametro b

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$\Rightarrow \hat{B}$ stimatore non distorto di b

Ma non conoscendo σ^2 , la stimiamo con lo **stimatore non distorto**:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right)$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$\Rightarrow \hat{B}$ stimatore non distorto di b

Ma non conoscendo σ^2 , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

$$\hat{B} := \frac{S_{XY}}{s_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{s_{XX}}\right)$$

$\Rightarrow \hat{B}$ stimatore non distorto di b

Ma non conoscendo σ^2 , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{s_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

e quindi

$$\frac{\hat{B} - b}{\sqrt{\hat{\Sigma}^2 / s_{XX}}} \sim t(n-2)$$

Inferenza su b

$$\hat{B} := \frac{S_{XY}}{s_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{s_{XX}}\right)$$

$\Rightarrow \hat{B}$ stimatore non distorto di b

Ma non conoscendo σ^2 , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{s_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

e quindi

$$\frac{\frac{\hat{B}-b}{\sqrt{\sigma^2/s_{XX}}}}{\frac{1}{\sqrt{n-2}} \sqrt{\frac{(n-2)\hat{\Sigma}^2}{\sigma^2}}} = \frac{\hat{B}-b}{\sqrt{\hat{\Sigma}^2/s_{XX}}} \sim t(n-2)$$

indip.

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \left(\hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \right) \text{ è un } IC_b(\gamma)$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \left(\hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \right) \text{ è un } IC_b(\gamma)$$

DIMOSTRAZIONE:

$$\begin{aligned} \mathbb{P} \left(b \in \left(\hat{B} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \right) \right) &= \\ &= \mathbb{P} \left(-t_{\frac{1+\gamma}{2}}(n-2) \leq \frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \leq t_{\frac{1+\gamma}{2}}(n-2) \right) \\ &= \gamma \end{aligned}$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) \text{”}$$

è un test di livello α per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) \text{”}$$

è un test di livello α per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$

DIMOSTRAZIONE:

$$\begin{aligned} \mathbb{P}_{H_0 \text{ vera}}(\text{“ rifiuto } H_0 \text{”}) &= \mathbb{P}_{b=b_0} \left(\underbrace{\left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right|}_{t(n-2)} > t_{1-\frac{\alpha}{2}}(n-2) \right) \\ &= \alpha \end{aligned}$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) \text{”}$$

è un test di livello α per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$

Se $b_0 = 0$, il test per le ipotesi

$$H_0 : b = 0 \quad \text{vs.} \quad H_1 : b \neq 0$$

verifica che le Y dipendano realmente da x (*significatività del modello*)

$$\hat{A} = \bar{Y} - \frac{S_{xY}}{s_{xx}} \bar{x} \sim N\left(a, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{A}$ stimatore non distorto di a

(dimostrazioni simili al caso per \hat{B})

$$\hat{A} = \bar{Y} - \frac{S_{xY}}{s_{xx}} \bar{x} \sim N\left(a, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{A}$ stimatore non distorto di a

$$\frac{\hat{A} - a}{\hat{\Sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}}} \sim t(n-2)$$

\Rightarrow IC e test per il parametro a

(dimostrazioni simili al caso per \hat{B})

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \text{residual standard error}$$

(stimatore *approx.* non distorto di σ)

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \text{residual standard error}$$

(stimatore *approx.* non distorto di σ)

$$\text{se}(\hat{A}) := \hat{\Sigma} \sqrt{\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)} \quad \text{standard error di } \hat{A}$$

(stimatore *approx.* non distorto di $\sqrt{\text{Var}[\hat{A}]}$)

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left(S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \text{residual standard error}$$

(stimatore *approx.* non distorto di σ)

$$\text{se}(\hat{A}) := \hat{\Sigma} \sqrt{\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)} \quad \text{standard error di } \hat{A}$$

(stimatore *approx.* non distorto di $\sqrt{\text{Var}[\hat{A}]}$)

$$\text{se}(\hat{B}) := \frac{\hat{\Sigma}}{\sqrt{S_{XX}}} \quad \text{standard error di } \hat{B}$$

(stimatore *approx.* non distorto di $\sqrt{\text{Var}[\hat{B}]}$)

Terminologia

La terminologia corretta sarebbe (p.es. per \hat{B})

$$\text{se}(\hat{B}) = \sqrt{\text{Var}[\hat{B}]} = \frac{\sigma}{\sqrt{s_{xx}}} \quad \text{errore (o deviazione) standard di } \hat{B}$$

$$\widehat{\text{SE}}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{stimatore approx. non distorto di } \text{se}(\hat{B})$$

$$\widehat{\text{se}}(\hat{B}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad \text{stima (= realizzazione) di } \widehat{\text{SE}}(\hat{B})$$

Terminologia

La terminologia corretta sarebbe (p.es. per \hat{B})

$$\text{se}(\hat{B}) = \sqrt{\text{Var}[\hat{B}]} = \frac{\sigma}{\sqrt{s_{xx}}} \quad \text{errore (o deviazione) standard di } \hat{B}$$

$$\widehat{\text{SE}}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{stimatore approx. non distorto di } \text{se}(\hat{B})$$

$$\widehat{\text{se}}(\hat{B}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad \text{stima (= realizzazione) di } \widehat{\text{SE}}(\hat{B})$$

Ma con abuso di notazione, diremo semplicemente

$$\text{se}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{standard error di } \hat{B}$$

$$\text{se}(\hat{b}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad (\text{realizzazione dello}) \text{ standard error di } \hat{B}$$

Terminologia

In termini delle quantità precedenti:

$$\left(\hat{a} \pm t_{\frac{1+\gamma}{2}}(n-2) \text{se}(\hat{a}) \right)$$

$IC(\gamma)$ per a

$$\frac{\hat{A} - a_0}{\text{se}(\hat{A})} \sim t(n-2)$$

statistica test per un test su a

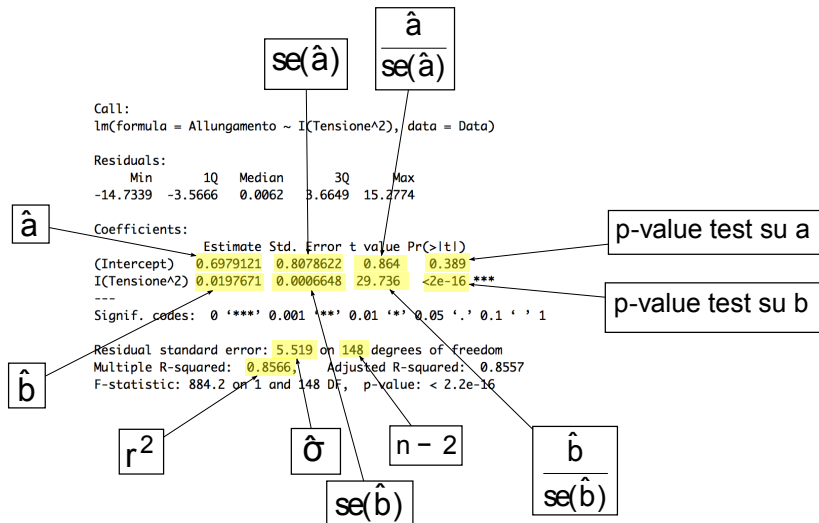
$$\left(\hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \text{se}(\hat{b}) \right)$$

$IC(\gamma)$ per b

$$\frac{\hat{B} - b_0}{\text{se}(\hat{B})} \sim t(n-2)$$

statistica test per un test su b

Output della regressione in R



Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

(1) $Y_i = a + bx_i + E_i$

(2) $E_i \sim N(0, \sigma^2)$

(3) E_1, \dots, E_n i.i.d.

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

Per verificare almeno (1) - (2), servirebbe un test di normalità sugli E_i

residui di $a + bx$

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

Per verificare almeno (1) - (2), servirebbe un test di normalità sugli E_i

MA

dai dati sappiamo ricavare solo gli $\hat{E}_i = Y_i - \hat{Y}_i$

residui della LSL

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Teorema (non dimostrato)

Se le (1) - (2) - (3) sono vere, allora i *residui standardizzati*

$$R_i := \frac{\hat{E}_i}{\hat{\Sigma}} = \frac{Y_i - (\hat{A} + \hat{B}x_i)}{\hat{\Sigma}}$$

- sono (approssimativamente) i.i.d.
- $R_i \approx N(0, 1)$

Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Teorema (non dimostrato)

Se le (1) - (2) - (3) sono vere, allora i *residui standardizzati*

$$R_i := \frac{\hat{E}_i}{\hat{\Sigma}} = \frac{Y_i - (\hat{A} + \hat{B}x_i)}{\hat{\Sigma}}$$

- sono (approssimativamente) i.i.d.
- $R_i \approx N(0, 1)$

\Rightarrow Possiamo fare un test di normalità per gli R_1, \dots, R_n !

Test per la bontà del modello lineare

Assumendo Y_1, \dots, Y_n indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli R_1, \dots, R_n

Test per la bontà del modello lineare

Assumendo Y_1, \dots, Y_n indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli R_1, \dots, R_n

Analizzando lo scatterplot degli r_1, \dots, r_n :

- non deve esserci una struttura definita (*omoschedasticità*)

Test per la bontà del modello lineare

Assumendo Y_1, \dots, Y_n indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli R_1, \dots, R_n

Analizzando lo scatterplot degli r_1, \dots, r_n :

- non deve esserci una struttura definita (*omoschedasticità*)
- i residui devono disporsi “a nuvola” intorno alla linea orizzontale

Test per la bontà del modello lineare

Assumendo Y_1, \dots, Y_n indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$


può quindi essere un qualunque test di normalità sugli R_1, \dots, R_n

Analizzando lo scatterplot degli r_1, \dots, r_n :


- non deve esserci una struttura definita (*omoschedasticità*)
- i residui devono disporsi “a nuvola” intorno alla linea orizzontale
- circa il 95% dei residui deve essere compreso tra -2 e $+2$

Due esempi

Standard Residuals vs. Fitted




QQ-Norm Residuals




OK modello lineare!

Due esempi

Standard Residuals vs. Fitted




QQ-Norm Residuals



NO modello lineare (forse quadratico)


IC per il valore atteso di una nuova osservazione



Ipotesi:

- E_1, \dots, E_n indipendenti $\Leftrightarrow Y_1, \dots, Y_n$ indipendenti
- $E_i \sim N(0, \sigma^2)$ $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$


IC per il valore atteso di una nuova osservazione



Ipotesi:

- E_1, \dots, E_n, E^* indipendenti $\Leftrightarrow Y_1, \dots, Y_n, Y^*$ indipendenti
- $E_i \sim N(0, \sigma^2)$ $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$
 $E^* \sim N(0, \sigma^2)$ $\Leftrightarrow Y^* \sim N(a + bx^*, \sigma^2)$

IC per il valore atteso di una nuova osservazione



Ipotesi:

- E_1, \dots, E_n, E^* indipendenti $\Leftrightarrow Y_1, \dots, Y_n, Y^*$ indipendenti
- $E_i \sim N(0, \sigma^2)$ $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$
- $E^* \sim N(0, \sigma^2)$ $\Leftrightarrow Y^* \sim N(a + bx^*, \sigma^2)$

Vogliamo trovare IC per il parametro

$$\mathbb{E}[Y^*] = a + bx^*$$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N$$



somma normali
indipendenti

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2\right)$$

somma normali
indipendenti

$$\begin{aligned}\mathbb{E}[\hat{A}] &= a \\ \mathbb{E}[\hat{B}] &= b\end{aligned}$$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}} \right)\right)$$

somma normali
indipendenti

$$\begin{aligned}\mathbb{E}[\hat{A}] &= a \\ \mathbb{E}[\hat{B}] &= b\end{aligned}$$

più complicato

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^* \text{ stimatore non distorto di } a + bx^*$$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$ stimatore non distorto di $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim N(0, 1)$$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$ stimatore non distorto di $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\hat{\Sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

IC per il valore atteso di una nuova osservazione

IPOTESI:

- Y_1, \dots, Y_n, Y^* indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$ stimatore non distorto di $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\hat{\Sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \left(\hat{a} + \hat{b}x^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)} \right) \text{ è un } IC_{a+bx^*}(\gamma)$$

Definizione

Siano $L = \ell(Y_1, \dots, Y_n)$ e $U = u(Y_1, \dots, Y_n)$ due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Intervalli di predizione per una nuova osservazione

Definizione

Siano $L = \ell(Y_1, \dots, Y_n)$ e $U = u(Y_1, \dots, Y_n)$ due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se y_1, \dots, y_n sono le realizzazioni di Y_1, \dots, Y_n , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello γ per la v.a. Y^* ($IP_{Y^*}(\gamma)$)

Intervalli di predizione per una nuova osservazione

Definizione

Siano $L = \ell(Y_1, \dots, Y_n)$ e $U = u(Y_1, \dots, Y_n)$ due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se y_1, \dots, y_n sono le realizzazioni di Y_1, \dots, Y_n , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello γ per la v.a. Y^* ($IP_{Y^*}(\gamma)$)

$$Y^* \sim N(a + bx^*, \sigma^2)$$

$a + bx^* \in \mathbb{R}$ **parametro incognito**

$$\mathbb{P}(L < a + bx^* < U) = \gamma$$

$$\Rightarrow (l, u) \text{ è un } IC_{a+bx^*}(\gamma)$$

Intervalli di predizione per una nuova osservazione

Definizione

Siano $L = \ell(Y_1, \dots, Y_n)$ e $U = u(Y_1, \dots, Y_n)$ due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se y_1, \dots, y_n sono le realizzazioni di Y_1, \dots, Y_n , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello γ per la v.a. Y^* ($IP_{Y^*}(\gamma)$)

$$Y^* \sim N(a + bx^*, \sigma^2)$$

$a + bx^* \in \mathbb{R}$ parametro incognito

$$\mathbb{P}(L < a + bx^* < U) = \gamma$$

$$\Rightarrow (l, u) \text{ è un } IC_{a+bx^*}(\gamma)$$

Y^* **variabile aleatoria**

$$\mathbb{P}(L < Y^* < U) = \gamma$$

$$\Rightarrow (l, u) \text{ è un } IP_{Y^*}(\gamma)$$

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

funzioni di Y_1, \dots, Y_n

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$
$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

$$\Rightarrow \left(\hat{y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right) \text{ è un } IP_{Y^*}(\gamma)$$

Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$


$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$


$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

$$\Rightarrow \left(\hat{y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \underbrace{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}}_{\text{più largo dell'IC}_{a+bx^*}(\gamma)}\right) \text{ è un } IP_{Y^*}(\gamma)$$


Regressione lineare multipla




Regressione lineare multipla




Regressione lineare multipla



Regressione lineare multipla




Regressione lineare multipla



Se facciamo n misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

Regressione lineare multipla




Se facciamo n misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

Ipotesi fondamentale del modello multilineare:

- E_1, \dots, E_n indipendenti $\Leftrightarrow Y_1, \dots, Y_n$ indipendenti
- $E_i \sim N(0, \sigma^2) \quad \forall i \quad \Leftrightarrow Y_i \sim N(a + \mathbf{x}_i^t \mathbf{b}, \sigma^2) \quad \forall i$

Regressione lineare multipla



Se facciamo n misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

Ipotesi fondamentale del modello multilineare:

- E_1, \dots, E_n indipendenti $\Leftrightarrow Y_1, \dots, Y_n$ indipendenti
- $E_i \sim N(0, \sigma^2) \quad \forall i \quad \Leftrightarrow Y_i \sim N(a + \mathbf{x}_i^t \mathbf{b}, \sigma^2) \quad \forall i$

Parametri incogniti: a, \mathbf{b}, σ^2

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1x_1 + \dots + b_kx_k = a + \mathbf{x}^t\mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) \quad i\text{-esimo residuo}$$

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) \quad i\text{-esimo residuo}$$

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2 \quad \text{funzionale di errore}$$

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b})$$

i -esimo residuo

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2$$

funzionale di errore

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{pmatrix}}_{n \times (k+1)} \quad \beta = \underbrace{\begin{pmatrix} a \\ b_1 \\ \vdots \\ b_k \end{pmatrix}}_{(k+1) \times 1}$$

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b})$$

i -esimo residuo

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2$$

funzionale di errore

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \beta = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1}$$

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) = y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i \quad i\text{-esimo residuo}$$

$$\begin{aligned} L(a, \mathbf{b}) &:= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2 && \text{funzionale di errore} \\ &= \sum_i (y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i)^2 \end{aligned}$$

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \boldsymbol{\beta} = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1} =: \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

Iperpiano dei minimi quadrati

PROBLEMA: Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola n punti $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$ assegnati in \mathbb{R}^{k+1}

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) = y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i \quad i\text{-esimo residuo}$$

$$\begin{aligned} L(a, \mathbf{b}) &:= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2 && \text{funzionale di errore} \\ &= \sum_i (y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i)^2 = \|\mathbf{y} - \tilde{\mathbf{x}}\boldsymbol{\beta}\|^2 \end{aligned}$$

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \boldsymbol{\beta} = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1} =: \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \mathbf{y} = \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}}_{n \times 1}$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = \text{?????}$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta)$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y}$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

se $\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}$ è invertibile $\implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y}$

P. es., con $k = 1$ predittore:

$$\tilde{\mathbf{x}}^t\tilde{\mathbf{x}} = \begin{pmatrix} n & n\bar{x} \\ n\bar{x} & s_{xx} + n\bar{x}^2 \end{pmatrix} \text{ è invertibile } \Leftrightarrow s_{xx} \neq 0$$

Altrimenti: *collinearità*

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta} \quad \text{output dell'LSH}$$

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

$$\hat{e}_i := y_i - \hat{y}_i$$

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

output dell'LSH

residui dell'LSH

varianza spiegata

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

$$ss_t := \sum (y_i - \bar{y})^2$$

varianza totale

Iperpiano dei minimi quadrati

Minimizziamo $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$ rispetto a β :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

$$ss_t := \sum (y_i - \bar{y})^2 \equiv ss_r + ss_e$$

varianza totale

OVERFITTING = ridurre ss_e aumentando i regressori

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

Iperpiano dei minimi quadrati

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

Iperpiano dei minimi quadrati

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left(\begin{pmatrix} \beta \\ 0 \end{pmatrix} \right)$$

Iperpiano dei minimi quadrati

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left(\begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

Iperpiano dei minimi quadrati

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left(\begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

Perciò si preferisce usare l'*r²-adjusted*

$$r_A^2 := 1 - \frac{ss_e}{ss_t} \frac{n-1}{n-1-k}$$

Iperpiano dei minimi quadrati

OVERFITTING = ridurre ss_e aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left(\begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

Perciò si preferisce usare l' r^2 -adjusted

$$r_A^2 := 1 - \frac{ss_e}{ss_t} \frac{n-1}{n-1-k} \begin{cases} \leq r^2 \\ \text{decescente in } k \end{cases}$$

Stimatori, IC e test per i parametri

IPOTESI: $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$ $\boldsymbol{\beta}, \sigma^2$ parametri incogniti

Stimatori, IC e test per i parametri

IPOTESI: $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$ $\boldsymbol{\beta}, \sigma^2$ parametri incogniti

CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \quad \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \quad \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

Stimatori, IC e test per i parametri

IPOTESI: $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$ $\boldsymbol{\beta}, \sigma^2$ parametri incogniti

CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

$$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r \text{ stimatore corretto di } \beta_r$$

Stimatori, IC e test per i parametri

IPOTESI: $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$ $\boldsymbol{\beta}, \sigma^2$ parametri incogniti

CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

$$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r \text{ stimatore corretto di } \beta_r$$

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - k - 1) \quad \text{indipendente da } \hat{B}_r$$

$$\Rightarrow \hat{\Sigma}^2 = \frac{SS_E}{n - k - 1} \quad \text{stimatore corretto di } \sigma^2$$

Stimatori, IC e test per i parametri

IPOTESI: $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$ $\boldsymbol{\beta}, \sigma^2$ parametri incogniti

CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{X}}^t \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^t \mathbf{y} \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \hat{\mathbf{B}} = (\tilde{\mathbf{X}}^t \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

$$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{X}}^t \tilde{\mathbf{X}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r \text{ stimatore corretto di } \beta_r$$

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - k - 1) \quad \text{indipendente da } \hat{B}_r$$

$$\Rightarrow \hat{\Sigma}^2 = \frac{SS_E}{n - k - 1} \quad \text{stimatore corretto di } \sigma^2$$

$$\Rightarrow \text{se}(\hat{B}_r) = \sqrt{\hat{\Sigma}^2 [(\tilde{\mathbf{X}}^t \tilde{\mathbf{X}})^{-1}]_{rr}} \quad \text{stimatore approx. corretto di } \sqrt{\text{Var}[\hat{B}_r]}$$

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$

⇐

$$\left(\hat{\beta}_r \pm t_{\frac{1+\gamma}{2}}(n - k - 1) \text{se}(\hat{\beta}_r) \right)$$

è un $IC(\gamma)$ per β_r

Stimatori, IC e test per i parametri

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$



$$\left(\hat{\beta}_r \pm t_{\frac{1+\gamma}{2}}(n - k - 1) \text{se}(\hat{\beta}_r) \right)$$

è un IC(γ) per β_r

“Rifiuto H_0 se

$$\left| \frac{\hat{B}_r - \beta_{r0}}{\text{se}(\hat{B}_r)} \right| > t_{1-\frac{\alpha}{2}}(n - k - 1)”$$

è un test di livello α per le ipotesi

$$H_0 : \beta_r = \beta_{r0} \quad \text{vs.} \quad H_1 : \beta_r \neq \beta_{r0}$$

Eliminazione a ritroso dei predittori non significativi

$k = k_0$, predittori x_1, \dots, x_{k_0}

Eliminazione a ritroso dei predittori non significativi

$k = k_0$, predittori x_1, \dots, x_{k_0}



Con R, ricavare l'output della regressione

Eliminazione a ritroso dei predittori non significativi

$k = k_0$, predittori x_1, \dots, x_{k_0}



Con R, ricavare l'output della regressione



Ordinare x_1, \dots, x_k in modo che i k test
 $H_0 : \beta_r = 0$ vs. $H_1 : \beta_r \neq 0$
abbiano p -value $p_1 < p_2 < \dots < p_k$

Eliminazione a ritroso dei predittori non significativi

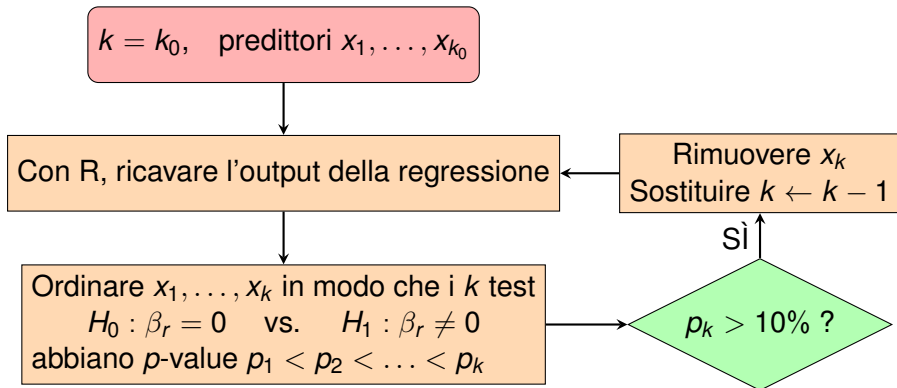
$k = k_0$, predittori x_1, \dots, x_{k_0}

Con R, ricavare l'output della regressione


Ordinare x_1, \dots, x_k in modo che i k test
 $H_0 : \beta_r = 0$ vs. $H_1 : \beta_r \neq 0$
abbiano p -value $p_1 < p_2 < \dots < p_k$

$p_k > 10\% ?$

Eliminazione a ritroso dei predittori non significativi



Eliminazione a ritroso dei predittori non significativi



Output della regressione in R

Call:

```
lm(formula = Distance ~ Temperature + Fuel + I(Temperature^2),  
    data = D)
```

Residuals:

Min	1Q	Median	3Q	Max
-32.078	-8.482	-0.377	9.223	34.466

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.743e+02	7.902e+01	-2.206	0.0308 *
Temperature	2.321e+01	5.066e+00	4.581	2.03e-05 ***
Fuel	-2.981e-03	7.689e-02	-0.039	0.9692
I(Temperature^2)	-4.356e-01	8.139e-02	-5.352	1.10e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.27 on 68 degrees of freedom

Multiple R-squared: 0.631, Adjusted R-squared: 0.6147

F-statistic: 38.76 on 3 and 68 DF, p-value: 1.012e-14

p-value troppo alto!
Va eliminato

r_A^2 basso
(poca variabilità spiegata)

Test per la bontà del modello multilineare

Ipotesi del modello multilineare:

(1) Y_1, \dots, Y_n indipendenti

(2) $Y_i \sim N((1 \ \mathbf{x}_i^t) \boldsymbol{\beta}, \sigma^2)$

Test per la bontà del modello multilineare

Ipotesi del modello multilineare:

(1) Y_1, \dots, Y_n indipendenti

(2) $Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2)$

Supponendo vera (1), testiamo (2):

$$H_0 : \exists \beta, \sigma \quad \text{t. c.} \quad Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2) \quad \forall i = 1, \dots, n$$

$$H_1 : H_0 \text{ è falsa}$$

Test per la bontà del modello multilineare

Ipotesi del modello multilineare:

(1) Y_1, \dots, Y_n indipendenti

(2) $Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2)$

Supponendo vera (1), testiamo (2):

$$H_0 : \exists \beta, \sigma \quad \text{t. c.} \quad Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2) \quad \forall i = 1, \dots, n$$

$$H_1 : H_0 \text{ è falsa}$$

Se (1) - (2) sono vere, allora i *residui studentizzati*

$$R'_i := \frac{Y_i - \hat{Y}_i}{\hat{\Sigma} \sqrt{1 - h_{ii}}} = \frac{R_i}{\sqrt{1 - h_{ii}}} \quad \text{con} \quad h_{ii} = \left[\tilde{\mathbf{x}} (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \right]_{ii}$$

- sono (approssimativamente) i.i.d.
- $R'_i \approx N(0, 1)$

Test per la bontà del modello multilineare

Ipotesi del modello multilineare:

(1) Y_1, \dots, Y_n indipendenti

(2) $Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2)$

Supponendo vera (1), testiamo (2):

$$H_0 : \exists \beta, \sigma \quad \text{t. c.} \quad Y_i \sim N((1 \ \mathbf{x}_i^t) \beta, \sigma^2) \quad \forall i = 1, \dots, n$$


$$H_1 : H_0 \text{ è falsa}$$

Se (1) - (2) sono vere, allora i *residui studentizzati*


$$R'_i := \frac{Y_i - \hat{Y}_i}{\hat{\Sigma} \sqrt{1 - h_{ii}}} = \frac{R_i}{\sqrt{1 - h_{ii}}} \quad \text{con} \quad h_{ii} = \left[\tilde{\mathbf{x}} (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \right]_{ii}$$

- sono (approssimativamente) i.i.d. }
 - $R'_i \approx N(0, 1)$
- \Rightarrow test di normalità per R'_1, \dots, R'_n

Stima e IP per una nuova osservazione




Stima e IP per una nuova osservazione



IPOTESI: $E^* \sim N(0, \sigma^2)$ e indipendente da E_1, \dots, E_n

$\Rightarrow Y^* \sim N(\beta_0 + \beta_1 x_1^* + \dots + \beta_k x_k^*, \sigma^2)$ e indipendente da Y_1, \dots, Y_n

Stima e IP per una nuova osservazione




IPOTESI: $E^* \sim N(0, \sigma^2)$ e indipendente da E_1, \dots, E_n

$\Rightarrow Y^* \sim N(\beta_0 + \beta_1 x_1^* + \dots + \beta_k x_k^*, \sigma^2)$ e indipendente da Y_1, \dots, Y_n

$\hat{Y}^* := \hat{B}_0 + \hat{B}_1 x_1^* + \dots + \hat{B}_k x_k^*$ stimatore non distorto del parametro

$$\mathbb{E}[Y^*] = \beta_0 + \beta_1 x_1^* + \dots + \beta_k x_k^*$$

Stima e IP per una nuova osservazione



IPOTESI: $E^* \sim N(0, \sigma^2)$ e indipendente da E_1, \dots, E_n

$\Rightarrow Y^* \sim N(\beta_0 + \beta_1 x_1^* + \dots + \beta_k x_k^*, \sigma^2)$ e indipendente da Y_1, \dots, Y_n

$\hat{Y}^* := \hat{B}_0 + \hat{B}_1 x_1^* + \dots + \hat{B}_k x_k^*$ stimatore non distorto del parametro

$$\mathbb{E}[Y^*] = \beta_0 + \beta_1 x_1^* + \dots + \beta_k x_k^*$$

$IC_{\mathbb{E}[Y^*]}$ e $IP_{Y^*} \leftarrow$ comando `predict()` di R

Test per la significatività di un gruppo di predittori

Per vedere se il gruppo dei primi r predittori è significativo, si testano

$$H_0 : \underbrace{\beta_1 = \beta_2 = \dots = \beta_r = 0}_{\text{tutte contemporaneamente}}$$

$$H_1 : \underbrace{\beta_s \neq 0 \text{ per qualche } s = 1, \dots, r}_{\text{almeno una } \neq 0}$$

Test per la significatività di un gruppo di predittori

Per vedere se il gruppo dei primi r predittori è significativo, si testano

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_r = 0 \quad H_1 : \beta_s \neq 0 \text{ per qualche } s = 1, \dots, r$$

Un test di livello α è dato dalla regola

$$\text{“rifiuto } H_0 \text{ se } \frac{[SS_E(\text{ridotto}) - SS_E(\text{completo})]/r}{SS_E(\text{completo})/(n - k - 1)} > f_{1-\alpha}(r, n - k - 1)”$$

dove

$SS_E(\text{completo}) :=$ varianza residua del modello con tutti i k predittori

$SS_E(\text{ridotto}) :=$ varianza residua del modello senza i primi r predittori

Test per la significatività di un gruppo di predittori

Per vedere se il gruppo dei primi r predittori è significativo, si testano

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_r = 0 \quad H_1 : \beta_s \neq 0 \text{ per qualche } s = 1, \dots, r$$

Un test di livello α è dato dalla regola

$$\text{“rifiuto } H_0 \text{ se } \frac{[SS_E(\text{ridotto}) - SS_E(\text{completo})]/r}{SS_E(\text{completo})/(n - k - 1)} > f_{1-\alpha}(r, n - k - 1)”$$

dove

$SS_E(\text{completo}) :=$ varianza residua del modello con tutti i k predittori

$SS_E(\text{ridotto}) :=$ varianza residua del modello senza i primi r predittori

Se $k = r$, otteniamo un test per la significatività dell'intero modello:

$$\text{“rifiuto } H_0 \text{ se } \frac{[SS_R(\text{completo})]/k}{SS_E(\text{completo})/(n - k - 1)} > f_{1-\alpha}(k, n - k - 1)”$$

perchè $SS_E(\text{ridotto}) = SS_T(\text{completo})$ in questo caso

Output della regressione in R

Call:

```
lm(formula = Distance ~ Temperature + Fuel + I(Temperature^2),  
    data = D)
```

Residuals:

Min	1Q	Median	3Q	Max
-32.078	-8.482	-0.377	9.223	34.466

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.743e+02	7.902e+01	-2.206	0.0308 *
Temperature	2.321e+01	5.066e+00	4.581	2.03e-05 ***
Fuel	-2.981e-03	7.689e-02	-0.039	0.9692
I(Temperature^2)	-4.356e-01	8.139e-02	-5.352	1.10e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.27 on 68 degrees of freedom
Multiple R-squared: 0.631, Adjusted R-squared: 0.6147
F-statistic: 38.76 on 3 and 68 DF, p-value: 1.012e-14

k

n - k - 1

$$\frac{[SS_R(\text{completo})]/k}{SS_E(\text{completo})/(n - k - 1)}$$

p-value del test

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$H_1 : \beta_s \neq 0 \text{ per qualche } s = 1, \dots, k$$

Caso non lineare	Sostituzione	Linearizzazione
$y = a + bf(x)$	$x' = f(x)$	$y = a + bx'$

Generalizzazioni

Caso non lineare	Sostituzione	Linearizzazione
$y = a + bf(x)$	$x' = f(x)$	$y = a + bx'$
$y = a + b_1f(x_1) + b_2g(x_2)$	$x'_1 = f(x_1)$ $x'_2 = g(x_2)$	$y = a + b_1x'_1 + b_2x'_2$

Caso non lineare	Sostituzione	Linearizzazione
$y = a + bf(x)$	$x' = f(x)$	$y = a + bx'$
$y = a + b_1f(x_1) + b_2g(x_2)$	$x'_1 = f(x_1)$ $x'_2 = g(x_2)$	$y = a + b_1x'_1 + b_2x'_2$
$y = a + b_1x_1^2 + b_2x_2$	$x'_1 = x_1^2$	$y = a + b_1x'_1 + b_2x_2$

Caso non lineare	Sostituzione	Linearizzazione
$y = a + bf(x)$	$x' = f(x)$	$y = a + bx'$
$y = a + b_1f(x_1) + b_2g(x_2)$	$x'_1 = f(x_1)$ $x'_2 = g(x_2)$	$y = a + b_1x'_1 + b_2x'_2$
$y = a + b_1x_1^2 + b_2x_2$	$x'_1 = x_1^2$	$y = a + b_1x'_1 + b_2x_2$
$y = a + b_1x_1 + b_2x_1x_2$	$x'_2 = x_1x_2$	$y = a + b_1x_1 + b_2x'_2$

$$x'_2 = x_1x_2 \quad \text{termine di interazione}$$

Generalizzazioni

Caso non lineare	Sostituzione	Linearizzazione
$y = a + bf(x)$	$x' = f(x)$	$y = a + bx'$
$y = a + b_1f(x_1) + b_2g(x_2)$	$x'_1 = f(x_1)$ $x'_2 = g(x_2)$	$y = a + b_1x'_1 + b_2x'_2$
$y = a + b_1x_1^2 + b_2x_2$	$x'_1 = x_1^2$	$y = a + b_1x'_1 + b_2x_2$
$y = a + b_1x_1 + b_2x_1x_2$	$x'_2 = x_1x_2$	$y = a + b_1x_1 + b_2x'_2$

A noi interessa solo fare inferenza su a, b, b_1, b_2

⇒ Ci basta che $\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}$ sia invertibile!

$x_k \in \{c_1, c_2, \dots, c_l\}$ predittore categorico

(p.es., $x_k \in \{\text{rosso, verde, blu}\}$)

$x_k \in \{c_1, c_2, \dots, c_l\}$ predittore categorico

Definiamo $l - 1$ nuovi predittori $z_k, z_{k+1}, \dots, z_{k+l-2}$ con $z_r \in \{0, 1\}$:

z_k	z_{k+1}	z_{k+2}	\dots	x_k
0	0	0	\dots	c_1
1	0	0	\dots	c_2
0	1	0	\dots	c_3
0	0	1	\dots	c_4
\dots	\dots	\dots	\dots	\dots


e facciamo la regressione per i $k + l - 2$ predittori numerici

$$x_1, \dots, x_{k-1}, z_k, \dots, z_{k+l-2}$$

Generalizzazioni

$x_k \in \{c_1, c_2, \dots, c_l\}$ predittore categorico

Definiamo $l - 1$ nuovi predittori $z_k, z_{k+1}, \dots, z_{k+l-2}$ con $z_r \in \{0, 1\}$:



z_k	z_{k+1}	z_{k+2}	\dots	x_k
0	0	0	\dots	c_1
1	0	0	\dots	c_2
0	1	0	\dots	c_3
0	0	1	\dots	c_4
\dots	\dots	\dots	\dots	\dots

e facciamo la regressione per i $k + l - 2$ predittori numerici

$$x_1, \dots, x_{k-1}, z_k, \dots, z_{k+l-2}$$

Facciamo così perché vogliamo che $\tilde{\mathbf{x}}^t \tilde{\mathbf{x}}$ sia invertibile.

ESEMPIO: Due modelli diversi:

$$y = \begin{cases} a + bx & \text{se la caratteristica } z = 0 \\ c + dx & \text{se la caratteristica } z = 1 \end{cases}$$

ESEMPIO: Due modelli diversi:

$$y = \begin{cases} a + bx & \text{se la caratteristica } z = 0 \\ c + dx & \text{se la caratteristica } z = 1 \end{cases}$$

$$\Rightarrow y = a + b x + (c - a) z + (d - b) xz$$

ESEMPIO: Due modelli diversi:

$$y = \begin{cases} a + bx & \text{se la caratteristica } z = 0 \\ c + dx & \text{se la caratteristica } z = 1 \end{cases}$$

$$\Rightarrow y = \underbrace{a}_{\beta_0} + \underbrace{b}_{\beta_1} \underbrace{x}_{x_1} + \underbrace{(c-a)}_{\beta_2} \underbrace{z}_{x_2} + \underbrace{(d-b)}_{\beta_3} \underbrace{xz}_{x_3}$$

$$\Rightarrow y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

Un esempio

Il famoso esploratore e statistico Jack Bettazzi, recatosi in Groenlandia per condurre la sua ricerca sulle specie locali di foche, dopo mesi di rilievi e osservazioni riesce a misurare i seguenti caratteri di $n = 30$ esemplari: il numero di `anni` di vita dell'esemplare; il suo `peso` in Kg; e infine la sua `specie`, che può essere bianca, marrone o nera. Decide di impostare questo modello lineare per spiegare la variabile `peso` tramite l'età e la specie:

$$\text{peso}_i = \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i$$

con $\varepsilon_1, \dots, \varepsilon_{30}$ i.i.d. e $\varepsilon_i \sim N(0, \sigma^2)$. Nel modello, il regressore categorico `specie` è codificato come segue:

$$(\text{speciemarrone}, \text{specienera}) = \begin{cases} (0, 0) & \text{se la specie è bianca} \\ (1, 0) & \text{se la specie è marrone} \\ (0, 1) & \text{se la specie è nera} \end{cases}$$


Un esempio

Questi sono i dati che ha trovato:

```
> anni
[1]  7.8 24.2  2.4 16.1  2.0 10.2 19.5 14.7  2.2  5.5  3.4 10.9  1.7 11.1
[15] 14.2  5.0 22.7  5.8 15.1 20.2 13.0 24.2 22.9 14.8 16.9 23.3  4.4  4.8
[29] 21.0 26.2
> specie
[1] "bianca"  "nera"    "nera"    "nera"    "nera"    "marrone" "nera"
[8] "nera"    "marrone" "bianca"  "bianca"  "marrone" "marrone" "bianca"
[15] "nera"    "bianca"  "nera"    "nera"    "marrone" "bianca"  "bianca"
[22] "bianca"  "marrone" "marrone" "bianca"  "marrone" "marrone" "nera"
[29] "marrone" "bianca"
> peso
[1] 100.1 406.2  80.5 270.0 117.6 108.0 356.4 268.1  55.1  34.4  47.1
[12] 108.8  45.7 100.6 282.5  60.3 386.7 158.4 148.3 155.1 109.0 200.4
[23] 206.3 148.2 160.3 209.6  52.7 143.0 180.5 216.7
```

Un esempio

E questo è il loro scatterplot:



Un esempio

Call:

```
lm(formula = peso ~ anni + specie + anni:specie)
```

Residuals:

Min	1Q	Median	3Q	Max
-25.447	-6.275	2.071	5.379	23.053

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.71817	8.20343	2.282	0.0317 *
anni	7.47801	0.53113	14.080	4.28e-13 ***
speciemarrone	12.05817	11.39650	1.058	0.3006
specienera	53.24377	11.32394	4.702	8.86e-05 ***
anni:speciemarrone	0.07485	0.75225	0.100	0.9216
anni:specienera	6.36519	0.74566	8.536	9.82e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.1 on 24 degrees of freedom

Multiple R-squared: 0.9861, Adjusted R-squared: 0.9832

F-statistic: 340.6 on 5 and 24 DF, p-value: < 2.2e-16

R usa i due punti per il termine d'interazione

$$\begin{aligned} \text{peso}_i = & \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i \\ & + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i \end{aligned}$$

Un esempio

```
Call:
lm(formula = peso ~ anni + specie + anni:specie)
```

Residuals:

Min	1Q	Median	3Q	Max
-25.447	-6.275	2.071	5.379	23.053

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.71817	8.20343	2.282	0.0317 *
anni	7.47801	0.53113	14.080	4.28e-13 ***
speciemarrone	12.05817	11.39650	1.058	0.3006
specienera	53.24377	11.32394	4.702	8.86e-05 ***
anni:speciemarrone	0.07485	0.75225	0.100	0.9216
anni:specienera	6.36519	0.74566	8.536	9.82e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.1 on 24 degrees of freedom

Multiple R-squared: 0.9861, Adjusted R-squared: 0.9832

F-statistic: 340.6 on 5 and 24 DF, p-value: < 2.2e-16

E decide lui come codificare le categorie bianca, marrone e nera (qui ha scelto la codifica di prima)

$$\begin{aligned} \text{peso}_i = & \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i \\ & + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i \end{aligned}$$

Un esempio

```
Call:
lm(formula = peso ~ anni + specie + anni:specie)
```

Residuals:

Min	1Q	Median	3Q	Max
-25.447	-6.275	2.071	5.379	23.053

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.71817	8.20343	2.282	0.0317 *
anni	7.47801	0.53113	14.080	4.28e-13 ***
speciemarrone	12.05817	11.39650	1.058	0.3006
specienera	53.24377	11.32394	4.702	8.86e-05 ***
anni:speciemarrone	0.07485	0.75225	0.100	0.9216
anni:specienera	6.36519	0.74566	8.536	9.82e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.1 on 24 degrees of freedom

Multiple R-squared: 0.9861, Adjusted R-squared: 0.9832

F-statistic: 340.6 on 5 and 24 DF, p-value: < 2.2e-16

p-value bassissimo!

Forte evidenza che la specie nera
ha un'intercetta diversa dalle altre

$$\begin{aligned} \text{peso}_i = & \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i \\ & + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i \end{aligned}$$

Un esempio

```
Call:
lm(formula = peso ~ anni + specie + anni:specie)
```

Residuals:

Min	1Q	Median	3Q	Max
-25.447	-6.275	2.071	5.379	23.053

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	18.71817	8.20343	2.282	0.0317 *
anni	7.47801	0.53113	14.080	4.28e-13 ***
speciemarrone	12.05817	11.39650	1.058	0.3006
specienera	53.24377	11.32394	4.702	8.86e-05 ***
anni:speciemarrone	0.07485	0.75225	0.100	0.9216
anni:specienera	6.36519	0.74566	8.536	9.82e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.1 on 24 degrees of freedom

Multiple R-squared: 0.9861, Adjusted R-squared: 0.9832

F-statistic: 340.6 on 5 and 24 DF, p-value: < 2.2e-16

Ed evidenza ancora più forte che
la specie nera ha pure il coefficiente
angolare diverso dalle altre

$$\begin{aligned} \text{peso}_i = & \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i \\ & + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i \end{aligned}$$

Un esempio

```
Call:
lm(formula = peso ~ anni + specie + anni:specie)

Residuals:
    Min       1Q   Median       3Q      Max
-25.447  -6.275   2.071   5.379  23.053

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   18.71817    8.20343   2.282  0.0317 *
anni           7.47801    0.53113  14.080 4.28e-13 ***
speciemarrone  12.05817   11.39650   1.058  0.3006
specienera     53.24377   11.32394   4.702 8.86e-05 ***
anni:speciemarrone 0.07485    0.75225   0.100  0.9216
anni:specienera   6.36519    0.74566   8.536 9.82e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.1 on 24 degrees of freedom
Multiple R-squared:  0.9861,    Adjusted R-squared:  0.9832
F-statistic: 340.6 on 5 and 24 DF,  p-value: < 2.2e-16
```

Invece, non sembra esserci nessuna evidenza che l'intercetta e il coefficiente angolare della specie bianca e di quella marrone siano diversi. Però bisognerebbe eliminarli uno alla volta!

$$\text{peso}_i = \beta_0 + \beta_1 \text{anni}_i + \beta_2 \text{speciemarrone}_i + \beta_3 \text{specienera}_i \\ + \beta_4 \text{anni}_i \cdot \text{speciemarrone}_i + \beta_5 \text{anni}_i \cdot \text{specienera}_i + \varepsilon_i$$