

# Statistica - 15<sup>a</sup> lezione

18 maggio 2021

# Retta dei minimi quadrati

Dai punti  $(x_1, y_1), \dots, (x_n, y_n)$  distilliamo le 5 quantità

$$\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$$

$$s_{xx} := \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_{xy} := \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_{yy} := \sum_{i=1}^n (y_i - \bar{y})^2$$


Allora la retta che meglio interpola i punti è la LSL

$$y = \hat{a} + \hat{b}x$$


coi coefficienti

$$\hat{a} = \bar{y} - \frac{s_{xy}}{s_{xx}} \bar{x} \quad \hat{b} = \frac{s_{xy}}{s_{xx}}$$

# Il modello statistico




# Il modello statistico



Se facciamo  $n$  misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

# Il modello statistico




Se facciamo  $n$  misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

**Ipotesi fondamentale del modello lineare:**

- $E_1, E_2, \dots, E_n$  i. i. d.
- $E_i \sim N(0, \sigma^2)$  con  $\sigma^2$  incognita

# Il modello statistico




Se facciamo  $n$  misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Ipotesi fondamentale del modello lineare:

- $E_1, E_2, \dots, E_n$  i. i. d.
  - $E_i \sim N(0, \sigma^2)$  con  $\sigma^2$  incognita
- $$\Rightarrow \begin{cases} Y_i \sim N(a + bx_i, \sigma^2) \\ Y_1, \dots, Y_n \text{ indipendenti} \end{cases}$$

# Il modello statistico



Se facciamo  $n$  misure:

$$x_1, x_2, \dots, x_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + bx_i + E_i$$

Ipotesi fondamentale del modello lineare:

- $E_1, E_2, \dots, E_n$  i. i. d.
  - $E_i \sim N(0, \sigma^2)$  con  $\sigma^2$  incognita
- $$\Rightarrow \begin{cases} Y_i \sim N(a + bx_i, \sigma^2) \\ Y_1, \dots, Y_n \text{ indipendenti} \end{cases}$$

$Y_1, \dots, Y_n$  non sono identicamente distribuite

Quali sono le variabili aleatorie nel modello lineare ?



# Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{x} = \frac{1}{n} \sum x_i$	No

# Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{X} = \frac{1}{n} \sum X_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì

# Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{X} = \frac{1}{n} \sum X_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$s_{XX} = \sum (X_i - \bar{X})^2$	No

# Il modello statistico

Quali sono le variabili aleatorie nel modello lineare ?


Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{X} = \frac{1}{n} \sum X_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$S_{XX} = \sum (X_i - \bar{X})^2$	No
$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	$S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y})$	Sì

# Il modello statistico


Quali sono le variabili aleatorie nel modello lineare ?

Era:	Diventa:	Ora è una v.a.?
$\bar{x} = \frac{1}{n} \sum x_i$	$\bar{X} = \frac{1}{n} \sum X_i$	No
$\bar{y} = \frac{1}{n} \sum y_i$	$\bar{Y} = \frac{1}{n} \sum Y_i$	Sì
$s_{xx} = \sum (x_i - \bar{x})^2$	$S_{XX} = \sum (X_i - \bar{X})^2$	No
$s_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	$S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y})$	Sì
$s_{yy} = \sum (y_i - \bar{y})^2$	$S_{YY} = \sum (Y_i - \bar{Y})^2$	Sì
Ecc.		

# Il modello statistico




# Il modello statistico



$E_i$  = errori di misura (residui di  $y = a + bx$ )

**NON MISURABILI**  
perché  $a, b$  incogniti

# Il modello statistico




$E_i$  = errori di misura (residui di  $y = a + bx$ )

$\hat{Y} = \hat{A} + \hat{B}x$  interpola i punti  $(x_1, Y_1), \dots, (x_n, Y_n)$



# Il modello statistico




$E_i$  = errori di misura (residui di  $y = a + bx$ )

$\hat{Y} = \hat{A} + \hat{B}x$  interpola i punti  $(x_1, Y_1), \dots, (x_n, Y_n)$

Riguarderemo  $(\hat{A}, \hat{B})$  come stimatori di  $(a, b)$

# Il modello statistico



$E_i$  = errori di misura (residui di  $y = a + bx$ )

$\hat{Y} = \hat{A} + \hat{B}x$  interpola i punti  $(x_1, Y_1), \dots, (x_n, Y_n)$

Riguarderemo  $(\hat{A}, \hat{B})$  come stimatori di  $(a, b)$

$\hat{E}_i$  = residui di  $\hat{Y} = \hat{A} + \hat{B}x$

MISURABILI

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_j - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

## DIMOSTRAZIONE:

$\hat{B}$  comb. lineare di gaussiane indipendenti  $\Rightarrow \hat{B} \sim N$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

## DIMOSTRAZIONE:

$\hat{B}$  comb. lineare di gaussiane indipendenti  $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

## DIMOSTRAZIONE:

$\hat{B}$  comb. lineare di gaussiane indipendenti  $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\hat{B}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= b\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(\textcolor{red}{b}, \frac{\sigma^2}{S_{XX}}\right)$$

## DIMOSTRAZIONE:

$\hat{B}$  comb. lineare di gaussiane indipendenti  $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\textcolor{red}{\hat{B}}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= \textcolor{red}{b}\end{aligned}$$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

## DIMOSTRAZIONE:

$\hat{B}$  comb. lineare di gaussiane indipendenti  $\Rightarrow \hat{B} \sim N$

$$\begin{aligned}\mathbb{E}[\bar{Y}] &= \mathbb{E}\left[\frac{1}{n} \sum Y_i\right] = \frac{1}{n} \sum \mathbb{E}[Y_i] = \frac{1}{n} \sum (a + bx_i) \\ &= a + b\bar{x}\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\hat{B}] &= \frac{\sum (x_i - \bar{x})(\mathbb{E}[Y_i] - \mathbb{E}[\bar{Y}])}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})[a + bx_i - (a + b\bar{x})]}{\sum (x_i - \bar{x})^2} \\ &= b\end{aligned}$$

$$\text{Var}[\hat{B}] = \frac{\sigma^2}{S_{XX}} \quad (\text{più complicato})$$



$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$\Rightarrow \hat{B}$  stimatore non distorto di  $b$

Se conoscessimo  $\sigma^2$ , potremmo usare la v. a.

$$\frac{\hat{B} - b}{\sqrt{\sigma^2 / S_{XX}}} \sim N(0, 1)$$

per costruire IC e fare test per il parametro  $b$

$$\hat{B} := \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{S_{XX}}\right)$$

$\Rightarrow \hat{B}$  stimatore non distorto di  $b$

Ma non conoscendo  $\sigma^2$ , la stimiamo con lo **stimatore non distorto**:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right)$$

$$\hat{B} := \frac{S_{XY}}{s_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{s_{XX}}\right)$$

$\Rightarrow \hat{B}$  stimatore non distorto di  $b$

Ma non conoscendo  $\sigma^2$ , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{s_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

$$\hat{B} := \frac{S_{XY}}{s_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{s_{XX}}\right)$$

$\Rightarrow \hat{B}$  stimatore non distorto di  $b$

Ma non conoscendo  $\sigma^2$ , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{s_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

e quindi

$$\frac{\hat{B} - b}{\sqrt{\hat{\Sigma}^2 / s_{XX}}} \sim t(n-2)$$

# Inferenza su $b$

$$\hat{B} := \frac{S_{XY}}{s_{XX}} = \frac{\sum (x_i - \bar{x})(Y_i - \bar{Y})}{\sum (x_i - \bar{x})^2} \sim N\left(b, \frac{\sigma^2}{s_{XX}}\right)$$

$\Rightarrow \hat{B}$  stimatore non distorto di  $b$

Ma non conoscendo  $\sigma^2$ , la stimiamo con lo stimatore non distorto:

$$\hat{\Sigma}^2 := \frac{SS_E}{n-2} = \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{s_{XX}} \right)$$

Si dimostra che

$$\frac{(n-2)\hat{\Sigma}^2}{\sigma^2} \sim \chi^2(n-2) \quad \text{indipendente da } \hat{B}$$

e quindi

$$\frac{\frac{\hat{B}-b}{\sqrt{\sigma^2/s_{XX}}}}{\frac{1}{\sqrt{n-2}} \sqrt{\frac{(n-2)\hat{\Sigma}^2}{\sigma^2}}} = \frac{\hat{B}-b}{\sqrt{\hat{\Sigma}^2/s_{XX}}} \sim t(n-2)$$

indip.

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \left( \hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \right) \text{ è un } IC_b(\gamma)$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \left( \hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \right) \text{ è un } IC_b(\gamma)$$

## DIMOSTRAZIONE:

$$\begin{aligned} \mathbb{P} \left( b \in \left( \hat{B} \pm t_{\frac{1+\gamma}{2}}(n-2) \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \right) \right) &= \\ &= \mathbb{P} \left( -t_{\frac{1+\gamma}{2}}(n-2) \leq \frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \leq t_{\frac{1+\gamma}{2}}(n-2) \right) \\ &= \gamma \end{aligned}$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) ”$$

è un test di livello  $\alpha$  per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$



$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) \text{”}$$

è un test di livello  $\alpha$  per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$

## DIMOSTRAZIONE:

$$\begin{aligned} \mathbb{P}_{H_0 \text{ vera}}(\text{“ rifiuto } H_0 \text{”}) &= \mathbb{P}_{b=b_0} \left( \underbrace{\left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right|}_{t(n-2)} > t_{1-\frac{\alpha}{2}}(n-2) \right) \\ &= \alpha \end{aligned}$$

$$\frac{\hat{B} - b}{\hat{\Sigma} / \sqrt{s_{xx}}} \sim t(n-2)$$

$$\Rightarrow \text{“ Rifiuto } H_0 \text{ se } \left| \frac{\hat{B} - b_0}{\hat{\Sigma} / \sqrt{s_{xx}}} \right| \geq t_{1-\frac{\alpha}{2}}(n-2) \text{”}$$

è un test di livello  $\alpha$  per le ipotesi

$$H_0 : b = b_0 \quad \text{vs.} \quad H_1 : b \neq b_0$$

Se  $b_0 = 0$ , il test per le ipotesi

$$H_0 : b = 0 \quad \text{vs.} \quad H_1 : b \neq 0$$

verifica che le  $Y$  dipendano realmente da  $x$  (*significatività del modello*)

$$\hat{A} = \bar{Y} - \frac{S_{xY}}{s_{xx}} \bar{x} \sim N\left(a, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{A}$  stimatore non distorto di  $a$

(dimostrazioni simili al caso per  $\hat{B}$ )

$$\hat{A} = \bar{Y} - \frac{S_{xY}}{s_{xx}} \bar{x} \sim N\left(a, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{A}$  stimatore non distorto di  $a$

$$\frac{\hat{A} - a}{\hat{\Sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}}}} \sim t(n-2)$$

$\Rightarrow$  IC e test per il parametro  $a$

(dimostrazioni simili al caso per  $\hat{B}$ )

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \textit{residual standard error}$$

(stimatore *approx.* non distorto di  $\sigma$ )

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \text{residual standard error}$$

(stimatore *approx.* non distorto di  $\sigma$ )

$$\text{se}(\hat{A}) := \hat{\Sigma} \sqrt{\left( \frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)} \quad \text{standard error di } \hat{A}$$

(stimatore *approx.* non distorto di  $\sqrt{\text{Var}[\hat{A}]}$ )

$$\hat{\Sigma}^2 := \frac{1}{n-2} \left( S_{YY} - \frac{S_{XY}^2}{S_{XX}} \right) \quad (\text{stimatore non distorto di } \sigma^2)$$

$$\hat{\Sigma} := \sqrt{\hat{\Sigma}^2} \quad \text{residual standard error}$$

(stimatore *approx.* non distorto di  $\sigma$ )

$$\text{se}(\hat{A}) := \hat{\Sigma} \sqrt{\left( \frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)} \quad \text{standard error di } \hat{A}$$

(stimatore *approx.* non distorto di  $\sqrt{\text{Var}[\hat{A}]}$ )

$$\text{se}(\hat{B}) := \frac{\hat{\Sigma}}{\sqrt{S_{XX}}} \quad \text{standard error di } \hat{B}$$

(stimatore *approx.* non distorto di  $\sqrt{\text{Var}[\hat{B}]}$ )



# Terminologia

La terminologia corretta sarebbe (p.es. per  $\hat{B}$ )

$$\text{se}(\hat{B}) = \sqrt{\text{Var}[\hat{B}]} = \frac{\sigma}{\sqrt{s_{xx}}} \quad \text{errore (o deviazione) standard di } \hat{B}$$

$$\widehat{\text{SE}}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{stimatore approx. non distorto di } \text{se}(\hat{B})$$

$$\widehat{\text{se}}(\hat{B}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad \text{stima (= realizzazione) di } \widehat{\text{SE}}(\hat{B})$$

# Terminologia

La terminologia corretta sarebbe (p.es. per  $\hat{B}$ )

$$\text{se}(\hat{B}) = \sqrt{\text{Var}[\hat{B}]} = \frac{\sigma}{\sqrt{s_{xx}}} \quad \text{errore (o deviazione) standard di } \hat{B}$$

$$\widehat{\text{SE}}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{stimatore approx. non distorto di } \text{se}(\hat{B})$$

$$\widehat{\text{se}}(\hat{B}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad \text{stima (= realizzazione) di } \widehat{\text{SE}}(\hat{B})$$

Ma con abuso di notazione, diremo semplicemente

$$\text{se}(\hat{B}) = \frac{\hat{\Sigma}}{\sqrt{s_{xx}}} \quad \text{standard error di } \hat{B}$$

$$\text{se}(\hat{b}) = \frac{\hat{\sigma}}{\sqrt{s_{xx}}} \quad (\text{realizzazione dello}) \text{ standard error di } \hat{B}$$

# Terminologia

In termini delle quantità precedenti:

$$\left( \hat{a} \pm t_{\frac{1+\gamma}{2}}(n-2) \text{se}(\hat{a}) \right)$$

$IC(\gamma)$  per  $a$

$$\frac{\hat{A} - a_0}{\text{se}(\hat{A})} \sim t(n-2)$$

statistica test per un test su  $a$

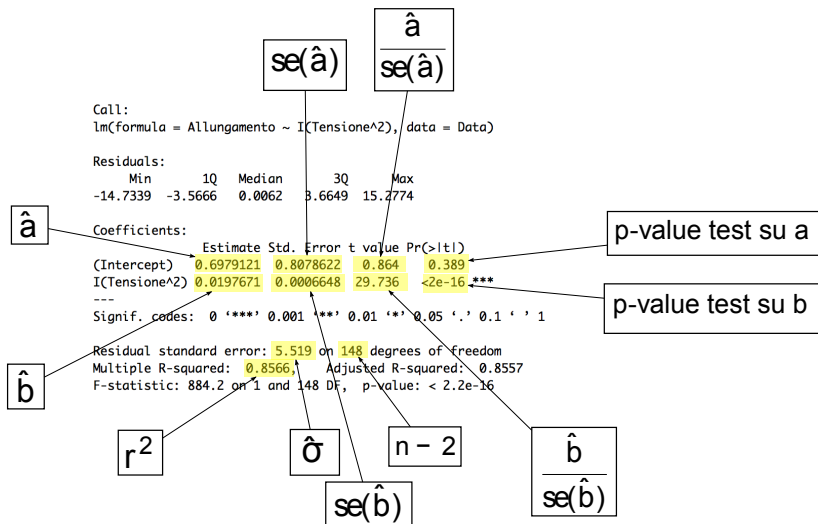
$$\left( \hat{b} \pm t_{\frac{1+\gamma}{2}}(n-2) \text{se}(\hat{b}) \right)$$

$IC(\gamma)$  per  $b$

$$\frac{\hat{B} - b_0}{\text{se}(\hat{B})} \sim t(n-2)$$

statistica test per un test su  $b$

# Output della regressione in R



# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

(1)  $Y_i = a + bx_i + E_i$

(2)  $E_i \sim N(0, \sigma^2)$

(3)  $E_1, \dots, E_n$  i.i.d.

# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

Per verificare almeno (1) - (2), servirebbe un test di normalità sugli  $E_i$

residui di  $a + bx$



# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

Ma come facciamo a verificarle?

Per verificare almeno (1) - (2), servirebbe un test di normalità sugli  $E_i$

MA

dai dati sappiamo ricavare solo gli  $\hat{E}_i = Y_i - \hat{Y}_i$

residui della LSL

# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

## Teorema (non dimostrato)

Se le (1) - (2) - (3) sono vere, allora i *residui standardizzati*

$$R_i := \frac{\hat{E}_i}{\hat{\Sigma}} = \frac{Y_i - (\hat{A} + \hat{B}x_i)}{\hat{\Sigma}}$$

- sono (approssimativamente) i.i.d.
- $R_i \approx N(0, 1)$

# Test per la bontà del modello lineare

Le ipotesi su cui si basa il modello sono

$$(1) Y_i = a + bx_i + E_i$$

$$(2) E_i \sim N(0, \sigma^2)$$

$$(3) E_1, \dots, E_n \text{ i.i.d.}$$



$$(A) Y_i \sim N(a + bx_i, \sigma^2)$$

$$(B) Y_1, \dots, Y_n \text{ indipendenti}$$

## Teorema (non dimostrato)

Se le (1) - (2) - (3) sono vere, allora i *residui standardizzati*

$$R_i := \frac{\hat{E}_i}{\hat{\Sigma}} = \frac{Y_i - (\hat{A} + \hat{B}x_i)}{\hat{\Sigma}}$$

- sono (approssimativamente) i.i.d.
- $R_i \approx N(0, 1)$

$\Rightarrow$  Possiamo fare un test di normalità per gli  $R_1, \dots, R_n$  !

# Test per la bontà del modello lineare

Assumendo  $Y_1, \dots, Y_n$  indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli  $R_1, \dots, R_n$

# Test per la bontà del modello lineare

Assumendo  $Y_1, \dots, Y_n$  indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli  $R_1, \dots, R_n$

Analizzando lo scatterplot degli  $r_1, \dots, r_n$ :

- non deve esserci una struttura definita (*omoschedasticità*)

# Test per la bontà del modello lineare

Assumendo  $Y_1, \dots, Y_n$  indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$

può quindi essere un qualunque test di normalità sugli  $R_1, \dots, R_n$

Analizzando lo scatterplot degli  $r_1, \dots, r_n$ :

- non deve esserci una struttura definita (*omoschedasticità*)
- i residui devono disporsi “a nuvola” intorno alla linea orizzontale

# Test per la bontà del modello lineare

Assumendo  $Y_1, \dots, Y_n$  indipendenti, un test per le ipotesi

$$H_0 : \exists a, b, \sigma \text{ tali che } Y_i \sim N(a + bx_i, \sigma^2) \quad \forall i = 1, \dots, n$$

vs.

$$H_1 : H_0 \text{ è falsa}$$


può quindi essere un qualunque test di normalità sugli  $R_1, \dots, R_n$

Analizzando lo scatterplot degli  $r_1, \dots, r_n$ :


- non deve esserci una struttura definita (*omoschedasticità*)
- i residui devono disporsi “a nuvola” intorno alla linea orizzontale
- circa il 95% dei residui deve essere compreso tra  $-2$  e  $+2$

# Due esempi

Standard Residuals vs. Fitted



QQ-Norm Residuals




OK modello lineare!




# Due esempi

Standard Residuals vs. Fitted




QQ-Norm Residuals



NO modello lineare (forse quadratico)


# IC per il valore atteso di una nuova osservazione



Ipotesi:

- $E_1, \dots, E_n$  indipendenti  $\Leftrightarrow Y_1, \dots, Y_n$  indipendenti
- $E_i \sim N(0, \sigma^2)$   $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$


# IC per il valore atteso di una nuova osservazione



Ipotesi:

- $E_1, \dots, E_n, E^*$  indipendenti  $\Leftrightarrow Y_1, \dots, Y_n, Y^*$  indipendenti
- $E_i \sim N(0, \sigma^2)$   $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$
- $E^* \sim N(0, \sigma^2)$   $\Leftrightarrow Y^* \sim N(a + bx^*, \sigma^2)$

# IC per il valore atteso di una nuova osservazione



Ipotesi:

- $E_1, \dots, E_n, E^*$  indipendenti  $\Leftrightarrow Y_1, \dots, Y_n, Y^*$  indipendenti
- $E_i \sim N(0, \sigma^2)$   $\Leftrightarrow Y_i \sim N(a + bx_i, \sigma^2)$
- $E^* \sim N(0, \sigma^2)$   $\Leftrightarrow Y^* \sim N(a + bx^*, \sigma^2)$

Vogliamo trovare IC per il parametro

$$\mathbb{E}[Y^*] = a + bx^*$$

# IC per il valore atteso di una nuova osservazione

## **IPOTESI:**

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N$$



somma normali  
indipendenti

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2\right)$$

somma normali  
indipendenti

$$\begin{aligned}\mathbb{E}[\hat{A}] &= a \\ \mathbb{E}[\hat{B}] &= b\end{aligned}$$

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left( \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}} \right)\right)$$

somma normali  
indipendenti

$$\begin{aligned}\mathbb{E}[\hat{A}] &= a \\ \mathbb{E}[\hat{B}] &= b\end{aligned}$$

più complicato



# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^* \text{ stimatore non distorto di } a + bx^*$$

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2)$ ,  $Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left( \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}} \right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$  stimatore non distorto di  $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\sigma^2 \left( \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}} \right)}} \sim N(0, 1)$$

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$  stimatore non distorto di  $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\hat{\Sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

# IC per il valore atteso di una nuova osservazione

## IPOTESI:

- $Y_1, \dots, Y_n, Y^*$  indipendenti
- $Y_i \sim N(a + bx_i, \sigma^2), Y^* \sim N(a + bx^*, \sigma^2)$

## CONSEGUENZE:

$$\hat{A} + \hat{B}x^* \sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$\Rightarrow \hat{Y}^* := \hat{A} + \hat{B}x^*$  stimatore non distorto di  $a + bx^*$

$$\frac{\hat{A} + \hat{B}x^* - (a + bx^*)}{\sqrt{\hat{\Sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \left( \hat{a} + \hat{b}x^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)} \right) \text{ è un } IC_{a+bx^*}(\gamma)$$

## Definizione

Siano  $L = \ell(Y_1, \dots, Y_n)$  e  $U = u(Y_1, \dots, Y_n)$  due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

# Intervalli di predizione per una nuova osservazione

## Definizione

Siano  $L = \ell(Y_1, \dots, Y_n)$  e  $U = u(Y_1, \dots, Y_n)$  due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se  $y_1, \dots, y_n$  sono le realizzazioni di  $Y_1, \dots, Y_n$ , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello  $\gamma$  per la v.a.  $Y^*$  ( $IP_{Y^*}(\gamma)$ )

# Intervalli di predizione per una nuova osservazione

## Definizione

Siano  $L = \ell(Y_1, \dots, Y_n)$  e  $U = u(Y_1, \dots, Y_n)$  due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se  $y_1, \dots, y_n$  sono le realizzazioni di  $Y_1, \dots, Y_n$ , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello  $\gamma$  per la v.a.  $Y^*$  ( $IP_{Y^*}(\gamma)$ )

$$Y^* \sim N(a + bx^*, \sigma^2)$$

$a + bx^* \in \mathbb{R}$  **parametro incognito**

$$\mathbb{P}(L < a + bx^* < U) = \gamma$$

$$\Rightarrow (l, u) \text{ è un } IC_{a+bx^*}(\gamma)$$

# Intervalli di predizione per una nuova osservazione

## Definizione

Siano  $L = \ell(Y_1, \dots, Y_n)$  e  $U = u(Y_1, \dots, Y_n)$  due statistiche tali che

$$\mathbb{P}(L < Y^* < U) = \gamma \quad (\text{con } \gamma \in (0, 1) \text{ fissato})$$

Allora, se  $y_1, \dots, y_n$  sono le realizzazioni di  $Y_1, \dots, Y_n$ , si dice che

$$(\ell(y_1, \dots, y_n), u(y_1, \dots, y_n))$$

è un *intervallo di predizione* di livello  $\gamma$  per la v.a.  $Y^*$  ( $IP_{Y^*}(\gamma)$ )

$$Y^* \sim N(a + bx^*, \sigma^2)$$

$a + bx^* \in \mathbb{R}$  parametro incognito

$$\mathbb{P}(L < a + bx^* < U) = \gamma$$

$\Rightarrow (l, u)$  è un  $IC_{a+bx^*}(\gamma)$

$Y^*$  **variabile aleatoria**

$$\mathbb{P}(L < Y^* < U) = \gamma$$

$\Rightarrow (l, u)$  è un  $IP_{Y^*}(\gamma)$



# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

funzioni di  $Y_1, \dots, Y_n$

# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$
$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$

$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$

$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

$$\Rightarrow \left(\hat{y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right) \text{ è un } IP_{Y^*}(\gamma)$$

# Intervalli di predizione per una nuova osservazione

$$\left. \begin{aligned} Y^* &\sim N(a + bx^*, \sigma^2) \\ \hat{Y}^* = \hat{A} + \hat{B}x^* &\sim N\left(a + bx^*, \sigma^2 \left(\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right) \end{aligned} \right\} \text{ indipendenti}$$


$$\Rightarrow Y^* - \hat{Y}^* \sim N\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)\right)$$

$$\frac{Y^* - \hat{Y}^*}{\sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}} \sim t(n-2)$$


$$\Rightarrow \mathbb{P}\left(Y^* \in \left(\hat{Y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \sqrt{\hat{\Sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}\right)\right) = \gamma$$

$$\Rightarrow \left(\hat{y}^* \pm t_{\frac{1+\gamma}{2}}(n-2) \underbrace{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}\right)}}_{\text{più largo dell'IC}_{a+bx^*}(\gamma)}\right) \text{ è un IP}_{Y^*}(\gamma)$$

# Regressione lineare multipla




# Regressione lineare multipla

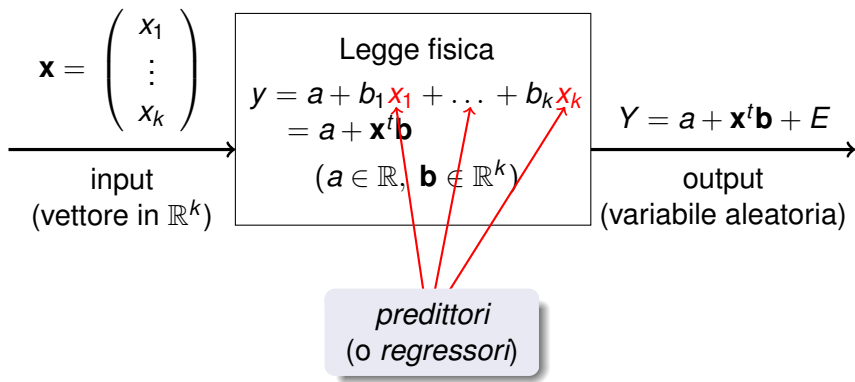





# Regressione lineare multipla



# Regressione lineare multipla




# Regressione lineare multipla



Se facciamo  $n$  misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

# Regressione lineare multipla




Se facciamo  $n$  misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

Ipotesi fondamentale del modello multilineare:

- $E_1, \dots, E_n$  indipendenti  $\Leftrightarrow Y_1, \dots, Y_n$  indipendenti
- $E_i \sim N(0, \sigma^2) \quad \forall i \quad \Leftrightarrow Y_i \sim N(a + \mathbf{x}_i^t \mathbf{b}, \sigma^2) \quad \forall i$

# Regressione lineare multipla



Se facciamo  $n$  misure:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \longrightarrow Y_1, Y_2, \dots, Y_n \quad \text{con} \quad Y_i = a + \mathbf{x}_i^t \mathbf{b} + E_i$$

Ipotesi fondamentale del modello multilineare:

- $E_1, \dots, E_n$  indipendenti  $\Leftrightarrow Y_1, \dots, Y_n$  indipendenti
- $E_i \sim N(0, \sigma^2) \quad \forall i \quad \Leftrightarrow Y_i \sim N(a + \mathbf{x}_i^t \mathbf{b}, \sigma^2) \quad \forall i$

Parametri incogniti:  $a, \mathbf{b}, \sigma^2$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1x_1 + \dots + b_kx_k = a + \mathbf{x}^t\mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1x_1 + \dots + b_kx_k = a + \mathbf{x}^t\mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t\mathbf{b}) \qquad i\text{-esimo residuo}$$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b})$$

$i$ -esimo residuo

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2$$

funzionale di errore



# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b})$$

$i$ -esimo residuo

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2$$

funzionale di errore

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{pmatrix}}_{n \times (k+1)} \quad \beta = \underbrace{\begin{pmatrix} a \\ b_1 \\ \vdots \\ b_k \end{pmatrix}}_{(k+1) \times 1}$$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b})$$

$i$ -esimo residuo

$$L(a, \mathbf{b}) := \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2$$

funzionale di errore

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \beta = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1}$$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) = y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i \quad i\text{-esimo residuo}$$

$$\begin{aligned} L(a, \mathbf{b}) &:= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2 && \text{funzionale di errore} \\ &= \sum_i (y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i)^2 \end{aligned}$$

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \boldsymbol{\beta} = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1} =: \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

# Iperpiano dei minimi quadrati

**PROBLEMA:** Valutare quanto bene l'iperpiano

$$y = a + b_1 x_1 + \dots + b_k x_k = a + \mathbf{x}^t \mathbf{b}$$

interpola  $n$  punti  $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$  assegnati in  $\mathbb{R}^{k+1}$

$$e_i := y_i - (a + \mathbf{x}_i^t \mathbf{b}) = y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i \quad i\text{-esimo residuo}$$

$$\begin{aligned} L(a, \mathbf{b}) &:= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (a + \mathbf{x}_i^t \mathbf{b})]^2 && \text{funzionale di errore} \\ &= \sum_i (y_i - (\tilde{\mathbf{x}}\boldsymbol{\beta})_i)^2 = \|\mathbf{y} - \tilde{\mathbf{x}}\boldsymbol{\beta}\|^2 \end{aligned}$$

$$\tilde{\mathbf{x}} = \underbrace{\begin{pmatrix} 1 & \mathbf{x}_1^t \\ 1 & \mathbf{x}_2^t \\ \dots & \dots \\ 1 & \mathbf{x}_n^t \end{pmatrix}}_{n \times (k+1)} \quad \boldsymbol{\beta} = \underbrace{\begin{pmatrix} a \\ \mathbf{b} \end{pmatrix}}_{(k+1) \times 1} =: \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \mathbf{y} = \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}}_{n \times 1}$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = \text{?????}$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta)$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$



# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y}$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

se  $\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}$  è invertibile  $\implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y}$

P. es., con  $k = 1$  predittore:

$$\tilde{\mathbf{x}}^t\tilde{\mathbf{x}} = \begin{pmatrix} n & n\bar{x} \\ n\bar{x} & s_{xx} + n\bar{x}^2 \end{pmatrix} \text{ è invertibile } \Leftrightarrow s_{xx} \neq 0$$

Altrimenti: *collinearità*

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta} \quad \text{output dell'LSH}$$

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \text{ è invertibile} \implies \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

$$ss_t := \sum (y_i - \bar{y})^2$$

varianza totale



# Iperpiano dei minimi quadrati

Minimizziamo  $L(\beta) = \|\mathbf{y} - \tilde{\mathbf{x}}\beta\|^2$  rispetto a  $\beta$ :

$$\nabla_{\beta} L(\beta) = -2\tilde{\mathbf{x}}^t(\mathbf{y} - \tilde{\mathbf{x}}\beta) = -2\tilde{\mathbf{x}}^t\mathbf{y} + 2\tilde{\mathbf{x}}^t\tilde{\mathbf{x}}\beta \equiv 0$$

$$\text{se } \tilde{\mathbf{x}}^t\tilde{\mathbf{x}} \xRightarrow{\text{è invertibile}} \beta = (\tilde{\mathbf{x}}^t\tilde{\mathbf{x}})^{-1}\tilde{\mathbf{x}}^t\mathbf{y} =: \hat{\beta}$$

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k = (1 \ \mathbf{x}^t) \hat{\beta} \quad \text{iperpiano dei minimi quadrati (LSH)}$$

Come nel caso semplice:

$$\hat{y}_i := (1 \ \mathbf{x}_i^t) \hat{\beta}$$

output dell'LSH

$$\hat{e}_i := y_i - \hat{y}_i$$

residui dell'LSH

$$ss_r := \sum (\bar{y} - \hat{y}_i)^2$$

varianza spiegata

$$ss_e := \sum (y_i - \hat{y}_i)^2$$

varianza residua

$$ss_t := \sum (y_i - \bar{y})^2 \equiv ss_r + ss_e$$

varianza totale

**OVERFITTING** = ridurre  $ss_e$  aumentando i regressori

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

# Iperpiano dei minimi quadrati

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

# Iperpiano dei minimi quadrati

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left( \begin{pmatrix} \beta \\ 0 \end{pmatrix} \right)$$

# Iperpiano dei minimi quadrati

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left( \begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

# Iperpiano dei minimi quadrati

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left( \begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

Perciò si preferisce usare l' *$r^2$ -adjusted*

$$r_A^2 := 1 - \frac{ss_e}{ss_t} \frac{n-1}{n-1-k}$$

# Iperpiano dei minimi quadrati

OVERFITTING = ridurre  $ss_e$  aumentando i regressori:

$$ss_e = L(\hat{\beta}) = \min_{\beta} L(\beta)$$

$$L_k(\beta) = \sum_i (y_i - \beta_0 - \beta_1 x_{i,1} - \dots - \beta_k x_{i,k})^2 \quad \beta \in \mathbb{R}^{k+1}$$

$$L_{k+1}(\beta') = \sum_i (y_i - \beta'_0 - \beta'_1 x_{i,1} - \dots - \beta'_{k+1} x_{i,k+1})^2 \quad \beta' \in \mathbb{R}^{k+2}$$

$$L_k(\beta) \equiv L_{k+1} \left( \begin{pmatrix} \beta \\ 0 \end{pmatrix} \right) \Rightarrow \min_{\beta} L_k(\beta) \geq \min_{\beta'} L_{k+1}(\beta')$$

Perciò si preferisce usare l' $r^2$ -adjusted

$$r_A^2 := 1 - \frac{ss_e}{ss_t} \frac{n-1}{n-1-k} \begin{cases} \leq r^2 \\ \text{decrescente in } k \end{cases}$$



# Stimatori, IC e test per i parametri

**IPOTESI:**  $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t)\boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$   $\boldsymbol{\beta}, \sigma^2$  parametri incogniti

# Stimatori, IC e test per i parametri

**IPOTESI:**  $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t)\boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$   $\boldsymbol{\beta}, \sigma^2$  parametri incogniti

## CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \quad \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \quad \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

# Stimatori, IC e test per i parametri

**IPOTESI:**  $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t)\boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$   $\boldsymbol{\beta}, \sigma^2$  parametri incogniti

## CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

$$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r \text{ stimatore corretto di } \beta_r$$

# Stimatori, IC e test per i parametri

**IPOTESI:**  $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t)\boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$   $\boldsymbol{\beta}, \sigma^2$  parametri incogniti

## CONSEGUENZE:

$$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y} \xrightarrow[\text{vettore di v.a.}]{\text{diventa il}} \hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y} \quad \text{con} \quad \mathbf{Y} = (Y_1, \dots, Y_n)^t$$

$$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r \text{ stimatore corretto di } \beta_r$$

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - k - 1) \quad \text{indipendente da } \hat{B}_r$$

$$\Rightarrow \hat{\Sigma}^2 = \frac{SS_E}{n - k - 1} \quad \text{stimatore corretto di } \sigma^2$$

# Stimatori, IC e test per i parametri

**IPOTESI:**  $\begin{cases} Y_1, \dots, Y_n & \text{indipendenti} \\ Y_i \sim N((1 \ \mathbf{x}_i^t)\boldsymbol{\beta}, \sigma^2) & \forall i \end{cases}$   $\boldsymbol{\beta}, \sigma^2$  parametri incogniti

## CONSEGUENZE:

$\hat{\boldsymbol{\beta}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{y}$   $\xrightarrow[\text{vettore di v.a.}]{\text{diventa il}}$   $\hat{\mathbf{B}} = (\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1} \tilde{\mathbf{x}}^t \mathbf{Y}$  con  $\mathbf{Y} = (Y_1, \dots, Y_n)^t$

$\hat{B}_r \sim N\left(\beta_r, \sigma^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}\right) \Rightarrow \hat{B}_r$  stimatore corretto di  $\beta_r$

$\frac{SS_E}{\sigma^2} \sim \chi^2(n - k - 1)$  indipendente da  $\hat{B}_r$

$\Rightarrow \hat{\Sigma}^2 = \frac{SS_E}{n - k - 1}$  stimatore corretto di  $\sigma^2$

$\Rightarrow \text{se}(\hat{B}_r) = \sqrt{\hat{\Sigma}^2 [(\tilde{\mathbf{x}}^t \tilde{\mathbf{x}})^{-1}]_{rr}}$  stimatore approx. corretto di  $\sqrt{\text{Var}[\hat{B}_r]}$

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$

⇐

$$\left( \hat{\beta}_r \pm t_{\frac{1+\gamma}{2}}(n - k - 1) \text{se}(\hat{\beta}_r) \right)$$

è un  $IC(\gamma)$  per  $\beta_r$

# Stimatori, IC e test per i parametri

$$\frac{\hat{B}_r - \beta_r}{\text{se}(\hat{B}_r)} \sim t(n - k - 1)$$



$$\left( \hat{\beta}_r \pm t_{\frac{1+\gamma}{2}}(n - k - 1) \text{se}(\hat{\beta}_r) \right)$$

è un IC( $\gamma$ ) per  $\beta_r$

“Rifiuto  $H_0$  se

$$\left| \frac{\hat{B}_r - \beta_{r0}}{\text{se}(\hat{B}_r)} \right| > t_{1-\frac{\alpha}{2}}(n - k - 1)”$$

è un test di livello  $\alpha$  per le ipotesi

$$H_0 : \beta_r = \beta_{r0} \quad \text{vs.} \quad H_1 : \beta_r \neq \beta_{r0}$$



# Eliminazione a ritroso dei predittori non significativi

$k = k_0$ , predittori  $x_1, \dots, x_{k_0}$

# Eliminazione a ritroso dei predittori non significativi

$k = k_0$ , predittori  $x_1, \dots, x_{k_0}$



Con R, ricavare l'output della regressione

# Eliminazione a ritroso dei predittori non significativi

$k = k_0$ , predittori  $x_1, \dots, x_{k_0}$

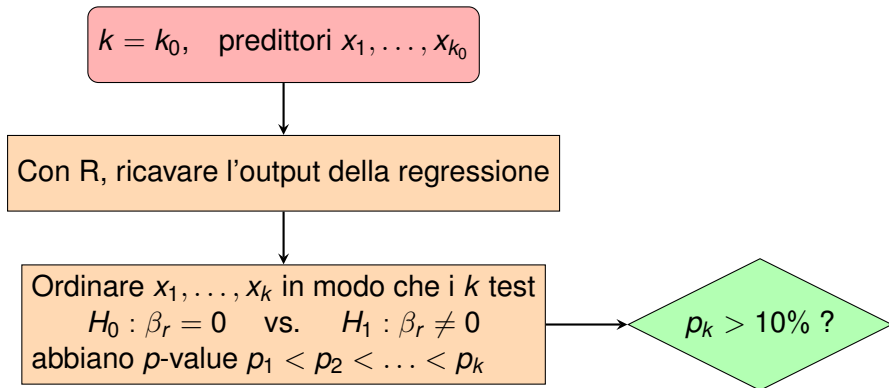


Con R, ricavare l'output della regressione




Ordinare  $x_1, \dots, x_k$  in modo che i  $k$  test  
 $H_0 : \beta_r = 0$  vs.  $H_1 : \beta_r \neq 0$   
abbiano  $p$ -value  $p_1 < p_2 < \dots < p_k$

# Eliminazione a ritroso dei predittori non significativi



# Eliminazione a ritroso dei predittori non significativi



# Eliminazione a ritroso dei predittori non significativi

